

# 基于位置社交网络的兴趣点推荐系统研究综述

陈江美<sup>1</sup>, 张文德<sup>2+</sup>

1. 福州大学 经济与管理学院, 福州 350108

2. 福州大学 信息管理研究所, 福州 350108

+ 通信作者 E-mail: zhangwd@fzu.edu.cn

**摘 要:** 兴趣点推荐是近年来位置社交网络和推荐系统领域研究的热点之一, 了解兴趣点推荐在位置社交网络方面的发展现状, 有利于为下一步的研究提供方向。对国内外兴趣点推荐系统的相关文献进行梳理, 首先介绍了兴趣点推荐系统的概念, 并从影响推荐的因素、推荐方法和推荐存在的问题三方面探讨其与传统推荐的区别。然后提出了兴趣点推荐系统的基本框架, 该框架包含了数据来源、推荐方法和算法评价三个核心部分。以该框架为基础, 介绍了影响兴趣点推荐的多种因素, 归纳了现有的兴趣点推荐算法, 总结了算法的评价指标。同时对代表性工作进行了分析介绍, 详细总结了各种方法的研究内容与特点, 并评价了其优势与不足。最后对该领域所面临的挑战和潜在的研究方向进行了总结与展望, 给出了未来的研究趋势和发展方向。

**关键词:** 位置社交网络; 推荐系统; 兴趣点推荐; 影响因素

**文献标志码:** A    **中图分类号:** TP391

## Review of Point of Interest Recommendation Systems in Location-Based Social Networks

CHEN Jiangmei<sup>1</sup>, ZHANG Wende<sup>2+</sup>

1. School of Economy and Management, Fuzhou University, Fuzhou 350108, China

2. Institute of Information Management, Fuzhou University, Fuzhou 350108, China

**Abstract:** Point of interest recommendation is recently one of the hotspots in the field of location-based social networks and recommendation systems. Understanding the research status of the point of interest recommendation in location-based social networks can provide a direction for the next step of work. The recent literatures of the point of interest recommendation systems are analyzed. Firstly, the definition is introduced, and the difference from traditional recommendation is discussed from three aspects: influencing factors, recommendation approaches and existing problems. Secondly, the general framework of the point of interest recommendation is proposed, which includes data sources, recommendation approaches and evaluation. Based on this framework, the various influencing factors are introduced, the current recommendation algorithms are generalized, and the evaluation metrics are summarized. Meanwhile, the representative works are analyzed, the research contents and characteristics of each type of methods are summarized in detail, and their advantages and limitations are evaluated. Finally, the challenges and potential directions for possible extensions in this filed are summarized and prospected, and the future research trends and development directions are concluded.

**Key words:** location-based social networks; recommendation systems; point of interest recommendation; influencing factor

**基金项目:** 国家自然科学基金青年项目(61300104); 中国高校产学研创新基金新一代信息技术创新项目(2019ITA0103)。

This work was supported by the National Natural Science Foundation for Youth of China (61300104) and the New Generation Information Technology Innovation Project of Industry-University-Research Innovation Fund in Chinese Universities (2019ITA0103).

收稿日期: 2021-12-09    修回日期: 2022-02-14

继在线社交网络发展和应用之后,移动社交网络成为新的发展方向,尤其是多样化的移动位置签到与共享等功能的不断普及。在此背景下,社交网络与位置服务不断融合,助推了基于位置社交网络(location-based social network, LBSN)的兴起<sup>[1]</sup>,如 Foursquare 和 Yelp。LBSN 利用用户的签到功能,有机地将线上和线下世界结合起来,提供用户位置定位功能的同时,还实现了位置信息在社交网络平台的共享,进而衍生出多样化的位置服务。推荐系统作为有效处理“信息过载”问题的重要工具<sup>[2]</sup>,旨在依据用户的个性化需求为用户推荐可能感兴趣的商品,其在位置服务领域的应用受到广泛关注。

近年来,将推荐系统应用到位置社交网络中,出现了诸多基于位置的推荐服务。其中,兴趣点(point of interest, POI)推荐受到了众多学者的关注。兴趣点是指用户签到的地点,如商场、学校等。兴趣点推荐能有效缓解位置信息过载问题,进而提升用户的个性化体验,同时有助于商家挖掘潜在的客户,提高商家的商业效益。为此,兴趣点推荐成为基于位置社交网络中的一项重要服务,是位置社交网络和推荐系统领域核心的研究方向之一。

LBSN 中蕴含着海量信息,兴趣点推荐主要利用用户历史签到记录及辅助信息从大量地点中为用户推荐心仪的地点。然而,兴趣点推荐是一项颇有挑战性的内容,用户的偏好受到多种因素的影响,这些影响推荐的因素类型繁多且复杂,传统的推荐方法难以有效构建用户的偏好模型,因此有必要充分发掘新的推荐方法,以适应兴趣点推荐服务的发展。同时,为了评估推荐算法的有效性,对推荐效果的评估与跟踪也是兴趣点推荐的重要研究内容。

根据以上的目标,本文在了解兴趣点推荐的基本概念与框架的基础上,从兴趣点推荐系统的研究中总结了三个核心问题:首先是分析影响兴趣点推荐的因素,即明确影响用户对兴趣点偏好的因素有哪些。本文归纳为用户自身的偏好、地理位置、社交关系、时间信息、内容信息与流行度。其次是探索现有的兴趣点推荐算法,即兴趣点推荐采用何种方法来建模用户对兴趣点的偏好,以构建合理高效的推荐模型。本文总结分析了基于矩阵分解算法的推荐、基于图嵌入的推荐与基于深度学习的推荐这三种方法的应用与发展。最后是算法的评价模块,即评估算法的性能与有效性。本文归纳了目前流行的几种预测指标及排序指标,并分析其应用情况。

为了更系统地了解兴趣点推荐的研究理论、现状、挑战和发展趋势,本文基于上述三个核心问题对国内外近年来相关的研究成果进行了梳理与解读。首先对兴趣点推荐系统的概念、与传统推荐的区别及基本框架进行了概述;其次在了解理论背景的基础上,总结归纳了影响兴趣点推荐的常见因素,从各个影响因素的角度分析兴趣点推荐的现状;然后阐述对比了现有的兴趣点推荐算法,并对代表性的工作进行了深入分析;根据兴趣点推荐的现状,重点对面临的问题和潜在的方向进行了概述;最后进行总结与展望,为兴趣点推荐系统后续的相关研究提供借鉴与参考,从而推动我国个性化推荐服务行业的进一步发展。

## 1 兴趣点推荐系统概述

移动社交网络的广泛普及,涌现了大量的位置服务功能,将推荐系统应用到位置服务,促进了基于位置社交网络的兴趣点推荐系统的发展。兴趣点推荐系统一般包含了用户集合  $U=\{u_1, u_2, \dots, u_m\}$  和兴趣点集合  $L=\{l_1, l_2, \dots, l_n\}$ ,  $m$  和  $n$  分别表示用户和兴趣点的个数。其中,每个兴趣点附带坐标属性,可用<经度,纬度>表示兴趣点的坐标位置。用户  $u$  对兴趣点的签到记录表示为  $L_u$ , 将用户的签到记录转换为用户-兴趣点交互矩阵  $R$ ,  $R$  中的每个元素  $R_{ui}$  表示了用户  $u$  对兴趣点  $i$  的签到次数,签到次数反映了用户的偏好。据此,基于位置的社交网络图可描绘如图 1 所示。




图1 基于位置的社交网络图

Fig.1 Location-based social network

兴趣点推荐作为传统在线推荐(如电影、图书和新闻推荐系统等)在社交网络领域的延伸,不仅能帮助用户维系现实世界中的社交关系,还能为用户提供个性化的服务。为了进一步理解兴趣点推荐系统,

以下将对其与传统推荐系统的区别及基本框架进行分析与总结。

### 1.1 传统推荐系统

传统推荐系统主要通过分析用户与项目间的二元关系<sup>[3]</sup>,利用评分信息构建用户对项目的偏好模型,以挖掘用户感兴趣的项目。通常利用  $U=\{u_1, u_2, \dots, u_m\}$  表示用户集,  $m$  表示用户的个数,利用  $I=\{i_1, i_2, \dots, i_n\}$  表示项目集,  $n$  表示项目的个数。用户与项目的关系如图2(a)所示,若用户对项目进行评分,则以连线的方式表示它们之间的交互。同时,将图2(a)的交互关系转化为图2(b)的用户-项目评分矩阵,矩阵中的元素为用户  $u$  对项目  $i$  的评分,空值表示用户未对此项目进行评分。在现实生活中,实际存在着海量的用户和项目数,而用户评分的项目个数有限,因此用户-项目评分矩阵极其稀疏,面临严重的数据稀疏问题,如何缓解稀疏问题以提高推荐性能是传统推荐系统的挑战之一。

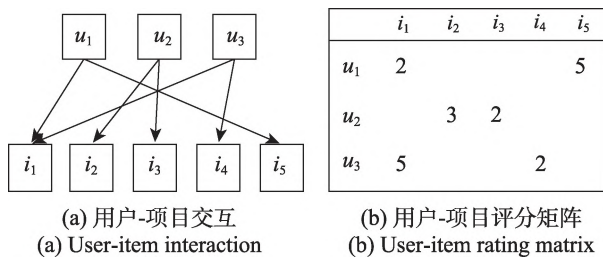


图2 用户交互数据

Fig.2 Users interaction data

在推荐系统中,推荐算法作为核心的技术,其性能的高低决定了推荐的效果。传统的推荐方法主要分为协同过滤推荐(collaborative filtering, CF)、基于内容的推荐(content-based)和混合推荐(hybrid),具体分类如图3所示。以下对三种推荐方法的内容及应用进行介绍。

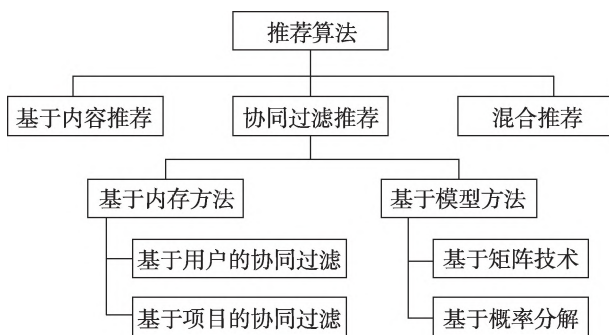


图3 推荐算法分类

Fig.3 Category of recommendation algorithms

#### (1) 协同过滤推荐

协同过滤算法作为推荐系统领域中最基础的方法<sup>[4-6]</sup>,主要利用用户-项目的历史评分数据来找出相似用户或项目。该算法主要分为基于内存的方法<sup>[4-5]</sup>和基于模型的方法<sup>[6]</sup>。基于内存的方法可进一步分为基于用户的协同过滤<sup>[4]</sup>和基于项目的协同过滤<sup>[5]</sup>,如图3所示。其中,基于用户的协同过滤认为具有相似偏好的用户具有相同的兴趣,基于项目的协同过滤则认为用户倾向于喜欢其之前感兴趣项目的相似项目,两者都是基于评分数据的推荐。另外,基于模型的方法主要采用机器学习(如矩阵分解算法、深度学习技术等)和数据挖掘技术(如聚类及分类算法等),通过评分矩阵数据不断训练得到模型参数,并建立相关的推荐模型,以预测用户的兴趣偏好。

在最早的推荐工作中,协同过滤算法常用来做评分预测。在兴趣点推荐领域,已有的研究<sup>[7-8]</sup>主要将情景信息融入协同过滤算法中。文献[7]将地理和社会信息嵌入基于用户的协同过滤框架中,预测用户的潜在偏好。文献[8]考虑实时推荐问题,将时间纳入协同过滤算法中,描述用户的时间偏好。因此,协同过滤算法由于模型的构建相对简单且易实现而得到了广泛应用。但算法本身极易遭受数据稀疏的影响,同时还存在冷启动问题,若单纯采用协同过滤算法,可能导致较低的推荐准确率。

#### (2) 基于内容的推荐

基于内容的推荐方法的基本思想主要是推荐用户与之前喜欢项目的类似项目<sup>[9]</sup>。首先分析用户的显隐性特征及相关文本信息,挖掘出与用户偏好有关的标签及项目的属性,接着度量项目间的相似性,将用户偏好的项目与其他项目的相似性排序,向用户推荐其潜在感兴趣的项目。该方法不需要评分记录,可有效解决协同过滤算法的冷启动问题,但推荐系统中可用的属性信息极为有限,具有一定的局限性。

#### (3) 混合推荐

为了克服上述两种方法的不足,出现了混合推荐策略。该方法主要将多种推荐算法融合,通过引入辅助信息来缓解数据稀疏和冷启动问题,进而改善推荐的准确率。文献[10-11]融合了基于协同过滤和基于内容的方法进行推荐。Guo等人<sup>[12]</sup>将协同过滤方法结合其他技术实现位置的推荐。Yuan等人<sup>[8]</sup>将时间分别融入协同过滤和矩阵分解框架中,采用混合推荐的方式实现兴趣点的动态推荐。因此,混合推荐方法被广泛应用,但算法的复杂性较高,且运行



时间较长,目前还需探索新的方法与技术应用到兴趣点推荐工作中。

## 1.2 兴趣点推荐与传统推荐的区别

兴趣点推荐指在传统的社交网络中增加位置信息,以便社交网络中的用户能直接共享兴趣点信息。与传统的推荐系统相比,由于LBSN中用户与兴趣点存在的相依性及兴趣点本身的独有属性(如时序性、粒度属性等)<sup>[13]</sup>,使得兴趣点推荐系统存在诸多异于传统推荐系统的特点。本文从影响推荐的因素、推荐方法及推荐存在的问题三方面进行分析比较。

(1)从影响推荐的因素考虑,传统的推荐系统主要利用评分数据进行预测和推荐。兴趣点推荐系统的影响因素主要包含用户签到数据和多类型的情景信息,如地理、时间、社交和兴趣点流行度等,并采用有效的算法构建模型以模拟用户的决策行为。另外,LBSN中多层级的网络结构使得用户的社交关系相较于传统推荐系统更为复杂,从而影响推荐因素的多样性。

(2)从推荐方法来看,传统的推荐只需根据用户的历史记录构建偏好模型,由2.1节可知,其主要采用协同过滤算法、基于内容的算法和混合推荐算法进行项目的推荐。由于兴趣点推荐相较于传统的推荐新增了位置信息及其附带的标签信息,采用传统的推荐算法可能无法满足复杂的推荐任务与精准推荐的需求,需要运用新技术解决更复杂的任务。例如,考虑兴趣点的标签信息,需采用深度学习等相关技术来挖掘兴趣点更深层次的隐特征,从而为用户推荐适合其偏好特征的兴趣点。因此,兴趣点推荐相较于传统的推荐需要更多技术支撑,才能更有效地完成推荐任务。

(3)从推荐工作存在问题的角度考虑,传统的推荐主要存在数据稀疏和冷启动两大问题。数据稀疏是指用户-项目评分矩阵多数为空值;冷启动是指系统如何给新用户进行推荐的问题。在兴趣点推荐工作中,还面临着序列推荐、动态推荐、个性化推荐和异地推荐等问题。序列推荐的任务是根据当前所在的位置,为用户推荐下一个可能签到的地点。在动态推荐问题上,Gao等人<sup>[14]</sup>最早将时间纳入兴趣点推荐,利用时间间隔划分用户-兴趣点签到矩阵。为了实现个性化推荐,文献[15-16]采用核密度估计方法描述用户的地理偏好,进而捕捉用户的移动行为。在异地推荐上,任星怡等人<sup>[17]</sup>采用了多种上下文信息建模用户偏好,从而实现异地推荐。因此,兴趣点推荐

面临更多样化的决策问题。

具体地,本文将传统推荐系统与兴趣点推荐系统的区别进行总结,如表1所示。

表1 传统推荐与兴趣点推荐的区别

Table 1 Difference between traditional recommendation and POI recommendation

比较类型	兴趣点推荐系统	传统的推荐系统
位置维度	有	无
信息来源	签到数据、情景信息	评分信息
数据类型	隐式数据	显式数据
推荐结果展示	基于评价的方式、列表方式	基于评价的方式
解决问题	数据稀疏、冷启动、序列推荐、动态推荐、个性化推荐、异地推荐	数据稀疏、冷启动

## 1.3 基本框架

近年来,学者们主要利用LBSN中用户的签到记录及情景信息模拟用户的决策行为,从而为用户推荐其可能感兴趣的地点。为了进一步了解兴趣点推荐的工作流程,总结得到一个通用的推荐框架如图4所示。该框架由三部分构成,即数据来源、推荐算法和算法评价。数据来源主要包括LBSN中用户和兴趣点的基本属性数据及相关的情景信息(即影响推荐的因素)。为此,本文将主要对影响兴趣点推荐的因素进行总结与阐述;推荐算法是推荐工作的核心,算法的性能决定了最终推荐的效果。本文将当前主流的兴趣点推荐算法分为矩阵分解算法、基于图嵌入的方法及基于深度学习的方法;算法评价是推荐的最后一步,利用相关的评价指标可有效评估算法的性能和效率,从而完成推荐任务。

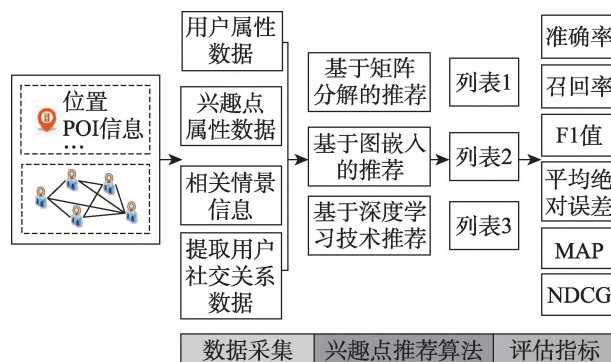


图4 兴趣点推荐系统的基本框架

Fig.4 Framework of POI recommendation system

为此,围绕兴趣点推荐系统的基本框架,本文接下来将对影响兴趣点推荐的因素、推荐算法及算法

评价指标这三方面的内容展开介绍,并对其代表性工作进行概述与对比。

## 2 影响兴趣点推荐的因素

兴趣点推荐通常受到多种因素的影响,其中用户对兴趣点的签到信息反映了用户的行为偏好,对于研究兴趣点推荐任务具有重大的应用价值。此外,位置社交网络中的情景信息影响着用户的决策和推荐的准确率。为此,本文将影响兴趣点工作的因素归纳为以下六方面:用户偏好<sup>[18-23]</sup>、地理信息<sup>[7,15-16,20-21,24-29]</sup>、社交关系<sup>[7,15,17,30-36]</sup>、时间信息<sup>[8,14,37-43]</sup>、内容信息<sup>[44-48]</sup>和流行度<sup>[8,17,29,49-51]</sup>。在此基础上,对探究各影响因素的相关工作进行分析与归纳。

### 2.1 用户偏好

用户的决策行为受自身偏好的影响极为显著,在兴趣点推荐工作中,用户的偏好可表现为用户签到兴趣点的次数与评论等。通常将用户的签到次数量化为偏好程度,若用户经常访问此地点,表明用户对兴趣点的偏好程度越高。Song等人<sup>[18]</sup>提取用户的签到数据并融合地理信息,采用基于用户的协同过滤算法为用户推荐兴趣点。Zhou等人<sup>[19]</sup>利用协同过滤算法对用户偏好进行个性化建模,并综合考虑了好友重要性与签到相关性的影响。但上述算法遭受数据稀疏的影响,性能有待进一步地改进。在此基础上,文献[20-21]利用矩阵分解算法学习用户偏好,通过用户的签到信息推测出用户和兴趣点的隐特征向量。另外,用户的评论内容反映了用户的偏好,若用户的评论内容为积极态度,如附带“喜欢”或“满意”等词,体现了用户对此兴趣点感兴趣。文献[20]利用聚合LDA(latent Dirichlet allocation)算法学习用户的评论信息,并将提取到的偏好与兴趣点的特征进行匹配。Xiong等人<sup>[22]</sup>提出概率生成模型实现用户特征偏好的提取。Xing等人<sup>[23]</sup>利用深度学习技术挖掘用户的评论信息,以学习用户的偏好。因此,充分利用用户的签到次数及评论信息可有效构建偏好模型,但由于用户决策的复杂性,需要进一步考虑情景信息对用户行为的影响,以更精准地推荐。

### 2.2 地理位置

地理位置是兴趣点推荐区别于传统推荐的根本特征。考虑用户倾向于签到距离较近的地点, Ye等人<sup>[7]</sup>提出幂律分布模型描述用户签到特征。Cheng等人<sup>[24]</sup>考虑用户偏向在多个中心点范围内签到,提出多中心的高斯分布模型。上述的模型采用相同的分布

函数捕捉用户的地理偏好,但每个用户应当具有独一无二的签到分布。据此,Zhang等人<sup>[15]</sup>采用核密度估计方法为每个用户分配唯一的概率密度函数。文献[16]对核密度估计方法进一步扩展,采用二维的坐标改进一维的距离来建模地理偏好,度量用户 $u$ 对未签到兴趣点 $l$ 的概率:

$$f(l|u_u) = \frac{1}{A} \sum_{j=1}^n (r_{uj} \cdot K_H(l-l_j)) \quad (1)$$

$$K_H(l-l_j) = \frac{1}{2\pi H_1 H_2} \exp\left(-\frac{(x_j-x)^2}{2H_1^2} - \frac{(y_j-y)^2}{2H_2^2}\right) \quad (2)$$

其中, $A$ 表示用户签到兴趣点的总次数; $K_H(l-l_j)$ 表示两个固定带宽( $H_1, H_2$ )的标准核函数。

为了实现用户个性化推荐,文献[20]对文献[16]的固定带宽加以改进,提出自适应带宽 $h_u$ :

$$h_u = \left( \left( \prod_{j=1}^n f(l|u_u) \right)^{-1} \cdot f(l|u_u) \right)^{-\beta} \quad (3)$$

$$K_{h_u}(l-l_j) = \frac{1}{2\pi H_1 H_2 h_u^2} \exp\left(-\frac{(x_j-x)^2}{2H_1^2 h_u^2} - \frac{(y_j-y)^2}{2H_2^2 h_u^2}\right) \quad (4)$$

其中, $\beta$ 是敏感参数。最终,利用文献[20]的自适应核密度估计模拟用户的行为,获取用户的预测偏好:

$$p_{ul}^G = F_{Geo}(l|u_u) = \frac{1}{A} \sum_{j=1}^n (r_{uj} \cdot K_{h_u}(l-l_j)) \quad (5)$$

上述研究主要对用户的地理行为建立统一的模型。近年来,将地理信息与其他影响推荐的因素融合成为趋势。文献[21,25-26]将地理与社交信息融合,利用矩阵分解算法求解用户与兴趣点的偏好特征。文献[27]提出地理-时间交互网络模型,探索兴趣点对之间的联系,实现下一个兴趣点的推荐。因此,探索地理信息的模型已较为成熟,如何进一步融合LBSN中的异构信息是下一步研究的重点。

### 2.3 社交关系

在位置推荐中,最初是利用协同过滤算法建模社交关系来实现用户偏好的预测<sup>[7,14,24]</sup>,但利用协同过滤方法时,用户相似度的度量易受局部异常点影响,且算法极易遭受稀疏问题,为此,矩阵分解方法受到关注。Qian等人<sup>[30]</sup>利用概率矩阵分解模型建模三种社交关系。Zhang等人<sup>[31]</sup>将用户的标签、社交和地理信息融入矩阵分解框架中,改善推荐性能。上述算法实质是利用LBSN中的好友关系预测用户对兴趣点的偏好分数。近年来,信任理论不断应用于推荐领域,基于信任的推荐已拓展到兴趣点推荐中。Zhu



等人<sup>[32]</sup>提出一种信任预测方法,综合考虑用户间的信任度与相似度向目标用户推荐好友,并融合用户偏好与地理影响。Xu等人<sup>[33]</sup>将用户偏好、社交关系与时空信息融入矩阵分解算法中,通过挖掘用户的直接信任和间接信任关系捕捉用户的社交影响。文献[34-36]利用图模型来表示用户的社交关系,图中相关节点的关系反映了用户间的交互,该方法取得了较显著的效果。由此可见,目前的研究主要是利用好友间的相似度和信任度来度量用户的社交影响,根据好友的喜好预测目标用户的偏好,未来的工作将需要探索更多高效的方法来捕获用户间的社交关系。

## 2.4 时间信息

用户对兴趣点的签到时间反映了用户的时间偏好,考虑用户的签到行为受时间信息的影响,会根据时间的变化呈现出周期性和序列性的行为。为了描述用户的周期性行为,Gao等人<sup>[14]</sup>考虑时间的差异性和连续性特征,并将此属性融入矩阵分解框架中,以刻画用户的时间特征。文献[8]将时间信息融入协同过滤算法中,并结合兴趣点的时间流行度进行推荐。上述算法主要采用时间间隔将用户-兴趣点签到矩阵划分为若干个签到矩阵,加剧了数据稀疏问题。基于此,Ying等人<sup>[37]</sup>提出非对称投影的时间感知嵌入方法刻画时间特征。文献[38]利用神经网络方法提取时间特征向量,能较好应对数据稀疏问题,进而改善推荐性能。在最新的一项研究中,Yin等人<sup>[39]</sup>考虑用户的时空偏好行为,将协同过滤算法与模糊聚类算法结合,有效地实现了兴趣点的动态推荐。

序列性签到行为在兴趣点推荐中主要表现为用户在当前时间签到对下一个时间签到地点产生的影响,即衍生出序列推荐问题。序列推荐侧重于为目标用户在一段时间内(如几个小时)推荐某些地点,是一项重要的推荐任务。文献[40]整合了时间和地理特征,构建了一个基于图的潜在表示模型,并结合LSTM(long short-term memory)神经网络来模拟用户复杂的移动行为,实现兴趣点的动态序列推荐。文献[41]提出将时空上下文信息输入到LSTM框架中,融合基于注意力机制模型来提取签到序列中的签到记录,以实现下一个兴趣点推荐。为了实现实时推荐,Wang等人<sup>[42]</sup>考虑了兴趣点的类型与签到时间,利用基于注意力机制的循环神经网络学习上下文信息,更好地预测用户下一个签到的兴趣点。基于此,Wu等人<sup>[43]</sup>丰富了上下文信息,采用线性组合的方式对用户的长短期偏好建模。该模型融合了类别信息和签

到时间,利用注意力机制捕捉用户的长期偏好,并基于兴趣点序列和类别序列建立两个LSTM模型来模拟用户的短期偏好。为此,现有的序列推荐工作主要融合时空信息,并应用神经网络及其拓展技术来实现。

综上,用户在时间信息上展现出的周期性与序列性的签到行为影响着用户的行为偏好,时间因素对兴趣点推荐的研究具有重要作用。

## 2.5 内容信息

兴趣点的内容信息影响着用户的决策,相关学者逐渐利用兴趣点的内容信息来挖掘其附带的属性特征,从而更有效率地实现用户的个性化推荐。Chen等人<sup>[44]</sup>将兴趣点的文本内容嵌入深度学习模型,更深层次地捕捉兴趣点的标签信息。Zhao等人<sup>[45]</sup>融合了兴趣点的情感属性和地理属性,利用概率矩阵分解技术挖掘用户与兴趣点的潜在特征。为了充分利用上下文信息,Zhang等人<sup>[46]</sup>运用社交网络中的图像内容和地理信息捕捉用户的偏好,采用加权矩阵分解算法学习用户及兴趣点的深层特征。上述的工作主要利用矩阵分解和深度学习来提取相关特征,以预测用户偏好。然而,LBSN中存在的多是异构数据,这些数据复杂且难以建模,探索更多的特征提取技术来处理异构数据是未来研究的重点。

## 2.6 流行度

流行度是指兴趣点受用户欢迎的程度,体现了兴趣点推荐系统提供的服务与质量。目前相关的研究普遍将兴趣点的流行度作为用户的先验知识。Yang等人<sup>[49]</sup>利用用户生成的文本和图像内容预测兴趣点的流行度,以缓解兴趣点信息的稀疏影响。兴趣点流行度具备时间属性,即实时性问题。Yao等人<sup>[50]</sup>考虑兴趣点的流行度受时间影响,提出将用户与兴趣点间的时间匹配度融入推荐框架中。Yuan等人<sup>[8]</sup>采用流行度信息衡量兴趣点被签到的先验概率,并将其与地理、时间信息融合,实现动态推荐。另外,Si等人<sup>[51]</sup>深入探索了流行度的影响,将连续签到时间段的流行度结合地理影响来完成推荐。该模型提出了两种推荐策略,对待活跃用户运用二维核密度估计建模地理偏好,对待非活跃用户运用一维幂律分布模拟地理影响,再分别融合时间流行度特征实现兴趣点推荐。上述研究主要将流行度和其他情景信息相结合,说明了流行度信息在推荐工作中的重要地位。

上述对影响兴趣点推荐的因素进行了阐述,并总结了相关代表性工作。表2分析了几种重要模型

考虑的影响因素,并归纳了算法的优点与局限性。文献[14,28]只考虑了单一信息的影响,因此推荐准确率较低。文献[17]融合了多种信息到矩阵分解算法中,可有效缓解数据稀疏性,但该算法未能充分挖掘兴趣点的特征。同时,为了探究不同因素的影响,文献[7]通过消融实验获得地理信息在推荐中的影响高于其他因素。文献[17]提出了本地和异地推荐两种情景,实验得出在异地场景中内容信息影响最大,在本地推荐场景中时间信息影响最大。以上说明了各影响因素在推荐工作中发挥的不同作用。此外,从表2可知,除了常见的几种情景信息外,文献[48]考虑了社交网络中的图像内容,利用矩阵分解和深度学习技术挖掘用户与兴趣点的特征,从而改善推荐性能。因此,现有研究还存在一定的局限性,仍有一些影响用户决策的因素未加以考虑,如天气、交通等,如何建模这些因素对推荐工作的影响是未来研究的重点。

### 3 兴趣点推荐算法

兴趣点推荐的影响因素类型多且复杂,利用传统的推荐方法(如协同过滤推荐方法等)无法进一步建模,因此衍生出不同类型的推荐算法与技术。目前的兴趣点推荐方法主要朝着矩阵分解算法<sup>[14,20-21,24-26,30-31,33,46,52-57]</sup>、基于图的方法<sup>[34-36,58-60]</sup>与基于深度学习<sup>[23,61-72]</sup>的方向发展。以下将重点对兴趣点推荐的核心算法及其相关代表工作进行详细阐述与对比总结。

#### 3.1 矩阵分解算法

矩阵分解算法(matrix factorization, MF)能有效缓解数据稀疏问题,且能够挖掘用户和兴趣点的特征,因此被广泛应用到推荐工作中。该方法采用降维的方式将用户-兴趣点矩阵  $R$  分解为低维空间上的用户隐特征矩阵  $U = \{U_1, U_2, \dots, U_m\} \in \mathbb{R}^{k \times n}$  和兴趣点隐特征矩阵  $V = \{V_1, V_2, \dots, V_n\} \in \mathbb{R}^{k \times m}$ ,  $k$  为隐特征个数,并通过训练使两者乘积  $\hat{R}_{ij}$  尽可能接近  $R$ , 其对应的优化问题如式(6)所示:

表2 兴趣点推荐的影响因素中各代表算法对比

Table 2 Comparison of typical algorithms in influencing factors of POI recommendation

代表算法	影响推荐因素	说明	优点	局限性	代码链接
USG <sup>[7]</sup>	用户偏好、地理、社交	将用户偏好融合到具有社会和地理影响的推荐框架	整合了多种情景信息	无法解决数据稀疏问题	<a href="http://spatialkeyword.sce.ntu.edu.sg/eval-vldb17/code/USG.zip">http://spatialkeyword.sce.ntu.edu.sg/eval-vldb17/code/USG.zip</a>
GeoMF <sup>[28]</sup>	地理	融合地理信息到加权矩阵分解算法模型	捕捉了用户的空间聚类现象	只考虑了地理位置影响	<a href="http://spatialkeyword.sce.ntu.edu.sg/eval-vldb17/code/GeoMF.zip">http://spatialkeyword.sce.ntu.edu.sg/eval-vldb17/code/GeoMF.zip</a>
iGSLR <sup>[15]</sup>	地理、社交	将社会影响和个性化地理影响整合到统一的推荐框架	实现了个性化的推荐	无法解决冷启动问题和数据稀疏问题	<a href="https://github.com/camcochet/iGSLR-Personalized-Geo-Social-Location-Recommendation">https://github.com/camcochet/iGSLR-Personalized-Geo-Social-Location-Recommendation</a>
LRT <sup>[14]</sup>	时间	提出时间的连续性和差异性特征,融入矩阵分解框架中	模拟了时间特征影响;实现了动态推荐	推荐准确率较低;只考虑了时间影响	<a href="http://spatialkeyword.sce.ntu.edu.sg/eval-vldb17/code/LRT.zip">http://spatialkeyword.sce.ntu.edu.sg/eval-vldb17/code/LRT.zip</a>
GTSCP <sup>[17]</sup>	地理、社交、时间、内容、流行度	将所有情景信息融入联合概率生成模型	适用于异地推荐场景;缓解数据稀疏问题	未解决兴趣点特征缺失的不足	N/A
LGLMF <sup>[29]</sup>	地理、流行度	考虑用户的主要活动区域及该区域内每个位置的相关性	可缓解数据稀疏性问题	未充分考虑其他情景信息的影响	<a href="https://paperswithcode.com/paper/lglm-local-geographical-based-logistic#code">https://paperswithcode.com/paper/lglm-local-geographical-based-logistic#code</a>
SLGMF <sup>[26]</sup>	地理、社交	融合社交和局部地理因素影响	可缓解数据稀疏性问题	融合的情景信息较有限	N/A
CRQA <sup>[47]</sup>	地理、内容	将空间和地理信息融合到联合推理模型中	可扩展到其他领域的推荐任务	只考虑了空间和文本推理	<a href="https://paperswithcode.com/paper/joint-spatio-textual-reasoning-for-answering#code">https://paperswithcode.com/paper/joint-spatio-textual-reasoning-for-answering#code</a>
MM-Gated-XAtt <sup>[48]</sup>	内容、图像	从各模态中提取相关信息来获取文本和图像间的交互	有效捕获多模态间的交互	未充分利用兴趣点与用户信息	<a href="https://github.com/danaesavi/poi-type-prediction">https://github.com/danaesavi/poi-type-prediction</a>

注:N/A表示相关文献未提及。

$$\min_{U,V} \frac{1}{2} \sum_{i=1}^{|U|} \sum_{j=1}^{|V|} \|R_{ij} - U_i^T V_j\|_F^2 \quad (6)$$

与传统推荐工作相比,兴趣点推荐不仅采用矩阵分解算法求解用户及项目的隐特征,还能进一步地将情景信息嵌入矩阵分解框架中,以预测用户的偏好。文献[33]将社交关系融入矩阵分解算法,采用添加正则项的方式求解用户偏好矩阵  $R$ ,通过优化式(7)模型来实现。其次,将用户关系兴趣矩阵  $H$  分解为用户关系隐特征矩阵  $W$  和兴趣点隐特征矩阵  $V$ ,求解  $H$  的优化函数如式(8)所示。最后,将式(7)与(8)联合求解,并采用随机梯度下降法优化式(9)的目标函数。

$$\min_{U,V} \frac{1}{2} \sum_{i=1}^{|U|} \sum_{j=1}^{|V|} \|R_{ij} - U_i^T V_j\|_F^2 + \lambda_u \sum_{i=1}^{|U|} \|U_i\|_F^2 + \lambda_v \sum_{j=1}^{|V|} \|V_j\|_F^2 \quad (7)$$

$$\min_{W,V} \frac{1}{2} \sum_{i,j=1}^{|W|} \|H_{ij} - W_i^T V_j\|_F^2 + \lambda_w \sum_{i,j=1}^{|W|} \|W_i\|_F^2 + \lambda_v \sum_{j=1}^{|V|} \|V_j\|_F^2 \quad (8)$$

$$\min \Omega(U, W, V) = \frac{\alpha_1}{2} \sum_{i=1}^{|U|} \sum_{j=1}^{|V|} \|R_{ij} - U_i^T V_j\|_F^2 + \frac{\alpha_2}{2} \sum_{i,j=1}^{|W|} \|H_{ij} - W_i^T V_j\|_F^2 + \lambda_u \sum_{i=1}^{|U|} \|U_i\|_F^2 + \lambda_w \sum_{i,j=1}^{|W|} \|W_i\|_F^2 + \lambda_v \sum_{j=1}^{|V|} \|V_j\|_F^2 \quad (9)$$

其中,  $\lambda_u$ 、 $\lambda_v$  与  $\lambda_w$  为正则化参数;矩阵元素  $H_{ij}$  为用户与好友对兴趣点的偏好度;  $\alpha_1$  与  $\alpha_2$  为调整因子。

在最新的推荐工作中,为了深度挖掘用户的潜在偏好,文献[52]将用户偏好、信任关系和时空信息融入到一个改进后的SVD矩阵分解框架中。该方法在原有模型的基础上提高了准确率,同时考虑了信任关系。对应的优化函数如下:

$$\arg \min f(P, Q) = \frac{1}{2} \sum_{u=1}^m \sum_{i=1}^n a_{ui} (R_{ui} - P_u^T Q_i)^2 + \frac{1}{2} \sum_{u=1}^m \sum_{v=1}^m S(u, v) \|Q_u - Q_v\|_F^2 + \frac{\lambda_u}{2} \|P\|_F^2 + \frac{\lambda_v}{2} \|Q\|_F^2 \quad (10)$$

在式(10)的目标函数中,第一项表示基本的用户偏好。此方法的创新之处在于第二项,  $S(u, v)$  表示用户相似度,结合了信任与时空信息,具体如式(11)所示:

$$S(u, v) = \frac{S(Z_u, Z_v)}{\sqrt{k(u_u)k(u_v)}} \sum_{i=1}^n \frac{(a_{ui}' + 1)(a_{vi}' + 1)Trust_{uv}}{\sqrt{k(o_i)}} \quad (11)$$

其中,  $S(Z_u, Z_v)$  定义为空间距离相关项;  $(a_{ui}' + 1)(a_{vi}' + 1)$

表示时间相关项;  $Trust_{uv}$  表示信任关系值。

另外, Davtalab 等人<sup>[53]</sup>融合了地理信息、射箭关系和时间信息到概率矩阵分解框架中。文献[54-55]采用联合矩阵分解的方法捕获用户的偏好,从而解决隐式反馈问题。上述算法利用不同类型的矩阵分解方法求解用户的偏好矩阵,适用于预测稀疏数据集的用户偏好,但缺点是这类方法往往训练时间较长。

### 3.2 基于图嵌入方法

基于图嵌入方法(graph embedding, GE)能够形象地将数据及其对应的关系刻画到图上,其兴起为社交网络的研究拓宽了新的思路。在LBSN中,兴趣点推荐往往包含着用户对兴趣点的偏好关系与用户社交关系。为此,可利用图模型将这两种关系描绘成图5所示的二分图网络<sup>[73]</sup>。在二分图网络中,用户若签到过兴趣点,则将两节点相连,若两个用户是好友关系,则利用边连接两个用户。近年来,图嵌入的方法得到了广泛的应用,接下来将对基于图的兴趣点推荐方法进行概括。




图5 二分图网络

Fig.5 Bipartite graph network

Zhu 等人<sup>[34]</sup>提出了一种融合社交与地理信息的图嵌入表示方法。该方法将用户嵌入与社交图嵌入结合获得用户的特征表示,将兴趣点嵌入与地理图嵌入结合获得兴趣点的特征表示。最终,在神经网络框架下捕获用户与兴趣点的潜在交互,从而得到用户的偏好。此模型可有效缓解协同过滤推荐算法无法解决的数据稀疏问题,并提高推荐质量。

Lu 等人<sup>[58]</sup>将图模型的方法应用到下一个兴趣点推荐的场景中,建立了一个改进的基于图的潜在表示模型,利用历史签到记录捕获时间序列影响与用户的时间偏好。在此基础上,使用LSTM神经网络模型扩展原有框架,以模拟用户复杂的移动行为。最终,利用学习到的潜在表示完成推荐任务,获得了较好的准确率。但此方法对社交网络中情景信息的挖掘不够充分,仍有待改善。

为了丰富情景信息,Qiao 等人<sup>[35]</sup>提出了一种健壮



的基于图嵌入的算法,能够有效解决社交网络中的异构性问题。该方法利用异构图融合了用户社交关系、地理和时间信息,生成了一个联合的表示学习框架。具体地,通过综合考虑情景信息的影响,得到异构图中节点间的转移概率,并利用异构图中的拓扑结构来学习用户与兴趣点的潜在表示。实验结果表明,该方法提升了推荐的性能,且能够处理兴趣点推荐中的冷启动问题。

Chen 等人<sup>[50]</sup>提出了一种多任务嵌入的个性化推荐方法,分别采用了序列嵌入和图嵌入的方式对用户的签到行为建模。该模型融合了序列数据、社交关系、语义信息和时空信息,利用序列嵌入方法捕获签到数据中的序列信息,再利用图嵌入的方式在用户-用户、用户-兴趣点和用户-时间等关系图中捕获情景信息的影响。该研究通过不同的嵌入方式探究各类信息的影响,有效地提高了推荐的性能。

在最新的一项研究中,Hu 等人<sup>[59]</sup>建立了一种模拟用户动态偏好的方法,目的在于有效地捕捉用户的细粒度偏好。该方法嵌入了地理和时间信息,旨在探究其对兴趣点级与项目级的影响,并融入到基于图嵌入的模型中,从而解决数据稀疏和冷启动问题,但不足之处在于可解释性较低。

上述对图嵌入方法在兴趣点推荐中的相关应用进行了介绍,借助图嵌入方法,能够利用图对 LBSN 中存在的用户、兴趣点和用户社交等节点关系进行建模,从而深入地挖掘社交网络间的关系,有效地将推荐问题转化为图中相关节点的交互问题,缓解了数据稀疏和冷启动问题。虽然基于图的方法为兴趣点推荐工作提供了新的方向,但其可解释性较低。随着深度学习的兴起,学者们逐渐将深度学习迁移到图上来,形成了图神经网络等重要方法,来进一步弥补上述方法的不足。

### 3.3 基于深度学习方法

鉴于传统的推荐方法在构建复杂模型时训练效果不佳,且利用矩阵分解算法易出现过拟合问题,深度学习技术受到了学者们的关注与青睐。深度学习(deep learning, DL)通过构建多层神经网络结构,对原始数据中的简单特征进行组合,从而能够获取更加抽象的语义特征表示。近年来,深度学习借由其强大的学习能力,以及能够深层次地表征用户与项目的潜在特征的特点,已被广泛地应用到推荐系统中。以下将对深度学习中各种神经网络在兴趣点推荐中的工作现状进行总结,主要包括针对卷积神经

网络、循环神经网络和图神经网络技术的推荐方法。

卷积神经网络(convolutional neural network, CNN)的基本结构如图6所示,包括输入层、卷积层、池化层、连接层与输出层。Xing 等人<sup>[61]</sup>考虑了地理位置、社交关系和评论信息,并将这些因素融合到一个基于卷积神经网络和概率矩阵分解模型的框架中,从而挖掘用户与兴趣点的特征。随着研究的深入,该团队将兴趣点的属性、用户偏好和情感信息融入卷积神经网络框架,利用神经网络捕捉评论内容中的语义信息,从而解决用户偏好的不可解释性问题和数据稀疏问题,生成了效果更优的潜在模型<sup>[23]</sup>。冯浩等人<sup>[62]</sup>利用卷积神经网络学习用户评论信息的特征,最终通过学习到的特征表示进行位置推荐,以改善算法的性能。




图6 卷积神经网络结构

Fig.6 Structure of convolutional neural network

循环神经网络(recurrent neural network, RNN)主要用于处理时间序列数据,大多数兴趣点推荐的研究主要应用该技术来完成序列推荐任务。Xia 等人<sup>[63]</sup>提出了一种基于注意力机制的循环神经网络,能根据相应用户的序列签到数据来模拟用户的生活模式。相较于传统的推荐方法,利用神经网络模型提高了算法的可解释性。Chen 等人<sup>[64]</sup>提出了一个有监督的循环神经网络学习预测模型,该模型考虑了用户的兴趣、地理位置和时间信息,最终形成了用户兴趣和上下文信息的综合特征表示。然而,上述的研究在对用户的短期偏好建模时忽略了用户的长期偏好,导致推荐结果不可靠。为此,Sun 等人<sup>[65]</sup>提出了一种新的适用于下一个兴趣点推荐的方法,该方法分别对用户的长短期偏好建模,并融合地理信息与用户的短期偏好到循环神经网络中。Huang 等人<sup>[66]</sup>考虑了相似用户的历史数据,利用循环神经网络与基于协同过滤算法建模用户的行为,从而捕捉用户的偏好。该模型克服了当前多层感知机与 LSTM 推荐方法的不足,在兴趣点推荐场景下得到了有效的应用。

基于图推荐方法的兴起为社交网络的研究拓宽了思路,学者们开始关注将深度学习模型运用到图数

据上,而图神经网络(graph neural network,GNN)成为其中最活跃的方法。Zhong 等人<sup>[67]</sup>提出混合图卷积网络模型,利用兴趣点对之间的地理距离构建空间图,采用图卷积网络表示兴趣点间的连通性,该模型为缓解数据稀疏问题提供了有效途径。为了建立更强大的推荐模型,Zhang 等人<sup>[68]</sup>利用图神经网络构建出一个包含用户节点和兴趣点节点的社交网络图,分别从节点信息和拓扑结构中学习节点的特征表示。用户节点利用了相邻社交节点和具有签到行为的兴趣点的表示来学习,并采用注意力机制来学习社交网络关系的异质结构。兴趣点节点融合了地理和时间信息特征,利用双向的长短期记忆模型来模拟用户的序列签到行为。该模型有效提高了推荐的效果,能普遍运用到各类推荐任务中。在实际应用中,Kang 等人<sup>[69]</sup>将监测站的位置制定为包含时间空间的图节点推荐问题,设计了一个有效的基于空气质量推断的高阶图卷积模型,进而捕捉空气质量分布的时空特征。该模型利用节点增量学习方法来判断节点的优先级顺序,最终依据优先级顺序完成推荐任务。

上述将深度学习中的CNN、RNN与GNN方法在

兴趣点推荐中的应用进行了对比与归纳,介绍了CNN技术在表征潜在特征方面的优势,总结了RNN在序列推荐上的应用以及GNN结合各情景信息来解决异构性问题,说明了深度学习是该领域应用的重要技术。为此,相关领域的学者应准确把握深度学习的最新发展趋势,为兴趣点推荐的发展寻求新的突破点。

综上,本文在传统推荐方法的基础上不断延伸,概括了基于矩阵分解的算法、基于图嵌入的方法和基于深度学习的方法的应用,分析了不同推荐方法目前已解决的问题。为了系统地了解各推荐方法的应用,表3对比归纳了各方法中代表性工作的特点、优缺点及相应的代码链接。

由表3可知,矩阵分解算法主要通过融合各情景信息,采用降维的方式求解用户与兴趣点的隐特征,进而预测用户偏好。该算法能够缓解数据稀疏问题,但训练时间较长,且会出现过拟合问题。基于图嵌入的方法通过构建关系图来反映用户与兴趣点的关系,并将各情景信息描述到图上,能缓解数据稀疏性,但存在可解释性较低等问题。深度学习技术与矩阵分解方法都具备挖掘用户与兴趣点特征的能力,相

表3 兴趣点推荐方法中各代表算法对比

Table 3 Comparison of typical algorithms in POI recommendation methods

推荐算法类别	代表算法	说明	优点	局限性	代码链接
基于矩阵分解的兴趣点推荐	ASMF <sup>[56]</sup>	考虑三类朋友来寻找每个用户的潜在兴趣点,并将地理和分类信息融入矩阵分解框架中	考虑了朋友的影响,同时可缓解数据稀疏问题	融合的情景信息较有限	<a href="https://paperswithcode.com/paper/point-of-interest-recommendations-learning#code">https://paperswithcode.com/paper/point-of-interest-recommendations-learning#code</a>
	GeoMF <sup>[28]</sup>	利用加权矩阵分解算法融合地理信息	捕捉了用户的空间聚类现象	考虑的情景信息单一	<a href="http://spatialkeyword.sce.ntu.edu.sg/eval-vldb17/code/GeoMF.zip">http://spatialkeyword.sce.ntu.edu.sg/eval-vldb17/code/GeoMF.zip</a>
	STACP <sup>[57]</sup>	将时空信息合并到矩阵分解模型中	可缓解数据稀疏问题;实现动态推荐	无法解决冷启动问题	<a href="https://paperswithcode.com/paper/joint-geographical-and-temporal-modeling#code">https://paperswithcode.com/paper/joint-geographical-and-temporal-modeling#code</a>
基于图嵌入的兴趣点推荐	UP2VEC <sup>[35]</sup>	利用异构图融合用户的社交、地理和时间信息	解决社交网络的异构性问题	模型的复杂度较高	N/A
	RELIN <sup>[60]</sup>	利用基于图的方法从各信息关系图中学习用户和兴趣点表示,并嵌入到潜在空间中	解决冷启动问题	未考虑节点属性	<a href="https://paperswithcode.com/paper/reline-point-of-interest-recommendations#code">https://paperswithcode.com/paper/reline-point-of-interest-recommendations#code</a>
	GLR <sup>[58]</sup>	利用基于图嵌入的方法捕获时间序列和用户时间偏好信息	可有效模拟用户复杂的移动行为	可解释性较低	N/A
基于深度学习的兴趣点推荐	DAN-SNR <sup>[70]</sup>	利用自注意力机制建模序列信息和社交影响	可有效表征用户与兴趣点的特征	模型的复杂度较高	<a href="https://paperswithcode.com/paper/dan-snr-a-deep-attentive-network-for-social#code">https://paperswithcode.com/paper/dan-snr-a-deep-attentive-network-for-social#code</a>
	GNN-POI <sup>[68]</sup>	利用图神经网络构建用户-兴趣点节点的网络图	适用于各类推荐任务	模型的复杂度较高	N/A
	STAN <sup>[71]</sup>	一种时空双向注意模型,充分考虑了相关位置的时空效应	考虑了非相邻位置和非连续签到位置的相关性	融合的情景信息较有限	<a href="https://paperswithcode.com/paper/stan-spatio-temporal-attention-network-for-l#code">https://paperswithcode.com/paper/stan-spatio-temporal-attention-network-for-l#code</a>

注:N/A表示相关文献未提及。

较于矩阵分解方法,深度学习技术能够更深层次地挖掘潜在特征,且具有强大的学习能力,主要缺点是模型的复杂度较高。为此,系统地了解各种方法的优劣与适用场景,将有利于兴趣点推荐工作的开展。

以上对影响兴趣点推荐的因素进行了分析,对各推荐算法的应用进行了描述,并详细介绍了相关代表性的工作,有利于理解现有兴趣点推荐的成果

及其优缺点。接下来,为了更综合、更全面地了解兴趣点推荐的发展现状,本文依据研究成果提出的时间顺序,以影响推荐的因素、解决的推荐问题及对应的推荐算法三方面为核心,探讨与总结各相关工作的推荐策略,进而充分地了解兴趣点推荐的研究现状。相关总结如表4所示。

由表4可知,兴趣点推荐已融合了各种影响因素

表4 兴趣点推荐的研究现状分析

Table 4 Analysis of research status in POI recommendation

影响因素和问题	推荐策略	推荐算法
影响因素	考虑用户签到兴趣点的概率与物理距离相关,提出幂律分布模型(Ye等 <sup>[7]</sup> ,2011)	Hybrid
	考虑用户在多个中心点范围内签到,提出多中心的高斯分布模型(Cheng等 <sup>[24]</sup> ,2012)	MF
	提出核密度估计方法建模用户的地理偏好(Zhang等 <sup>[15]</sup> ,2013)	Hybrid
	提出固定带宽核密度估计方法构建地理偏好模型(Zhang等 <sup>[16]</sup> ,2015)	—
	利用自适应核密度估计方法捕捉用户的地理偏好(任星怡等 <sup>[20]</sup> ,2017;Si等 <sup>[51]</sup> ,2019)	MF等
	将情景信息融入矩阵分解框架(任星怡等 <sup>[20]</sup> ,2017;彭宏伟等 <sup>[21]</sup> ,2019)	MF
	采用基于用户的协同过滤方法建模签到信息和地理信息(Song等 <sup>[18]</sup> ,2019)	CF
	将好友重要性与签到相关性融入协同过滤方法(Zhou等 <sup>[19]</sup> ,2019)	CF
	利用卷积神经网络挖掘用户评论中的语义信息(Xing等 <sup>[23]</sup> ,2019)	CNN
	利用概率矩阵分解模型建模社交关系(Qian等 <sup>[30]</sup> ,2014)	MF
	提出基于朋友的协同过滤方法(彭宏伟等 <sup>[21]</sup> ,2019)	CF
	将改进后的直接信任与间接信任融入矩阵分解算法(Xu等 <sup>[33]</sup> ,2021)	MF
	利用图嵌入的方法表示用户间的社交关系(Zhu等 <sup>[34]</sup> ,2019;Chen等 <sup>[36]</sup> ,2021)	GE
	利用图神经网络构建社交网络图(Zhang等 <sup>[68]</sup> ,2021)	GNN
	提出基于时间感知的兴趣点推荐模型(Yuan等 <sup>[8]</sup> ,2013)	Hybrid
	提出时间的差异性和连续性特征(Gao等 <sup>[14]</sup> ,2013)	MF
	提出基于非对称投影的时间感知嵌入方法(Ying等 <sup>[37]</sup> ,2019)	—
	利用时间信息捕捉用户的动态偏好(Ma等 <sup>[38]</sup> ,2020;Yin等 <sup>[39]</sup> ,2021)	RNN、Hybrid
	利用时间序列数据实现下一个兴趣点推荐(Chen等 <sup>[64]</sup> ,2020;Huang等 <sup>[66]</sup> ,2021)	RNN、Hybrid
	考虑兴趣点流行度影响用户的决策行为(Yuan等 <sup>[8]</sup> ,2013;任星怡等 <sup>[20]</sup> ,2017)	Hybrid、MF
	利用文本和图像信息预测兴趣点流行度(Yang等 <sup>[49]</sup> ,2019)	—
	将流行度特征结合二维的核密度估计与一维的幂律分布(Si等 <sup>[51]</sup> ,2019)	—
	将兴趣点的文本内容嵌入深度学习模型(Chen等 <sup>[44]</sup> ,2020)	Hybrid
	采用加权矩阵分解算法融合图像内容和地理信息(Zhang等 <sup>[46]</sup> ,2019)	MF
推荐问题	利用矩阵分解技术缓解稀疏问题(Gao等 <sup>[14]</sup> ,2013;温彦等 <sup>[25]</sup> ,2019)	MF
	利用图嵌入表示方法缓解稀疏性(Zhu等 <sup>[34]</sup> ,2019)	GE
	采用混合图卷积网络应对稀疏性问题(Zhong等 <sup>[67]</sup> ,2020)	GNN
	利用元路径挖掘用户行为间复杂的语义关系以表征新用户的属性(Yu等 <sup>[52]</sup> ,2019)	MF
	提出混合图神经网络模型改善冷启动问题(Zhong等 <sup>[67]</sup> ,2020)	GNN
	提出一种基于注意力机制的循环神经网络实现序列推荐(Xia等 <sup>[63]</sup> ,2017)	RNN
	提出改进的基于图的潜在表示模型来捕获时间序列影响(Lu等 <sup>[58]</sup> ,2020)	Hybrid
	利用循环神经网络学习情景信息来预测用户下一个签到的兴趣点(Wang等 <sup>[42]</sup> ,2021)	RNN
	提出兴趣点的受欢迎程度受时间影响(Yuan等 <sup>[8]</sup> ,2013)	Hybrid
	考虑用户偏好的动态变化特征(Gao等 <sup>[14]</sup> ,2013;Ying等 <sup>[37]</sup> ,2019;Ma等 <sup>[38]</sup> ,2020)	MF、RNN等
	利用协同过滤算法与模糊聚类算法捕捉用户的时空偏好(Yin等 <sup>[39]</sup> ,2021)	Hybrid
	提出核密度估计方法描述用户的地理行为(Zhang等 <sup>[16]</sup> ,2015;任星怡等 <sup>[20]</sup> ,2017)	MF等
	融合流行度与二维的核密度估计方法捕捉活跃用户的偏好(Si等 <sup>[51]</sup> ,2019)	—
	提出概率生成模型模拟用户在异地的决策行为(任星怡等 <sup>[17]</sup> ,2017)	—



来构建模型,且取得了显著的成效。在解决推荐问题方面,对数据稀疏、冷启动、个性化、序列与动态推荐问题的研究颇为丰富,未来研究应将重点放在异地推荐问题上。在推荐算法上,可看出早年主要以协同过滤算法为基础,接着逐渐利用矩阵分解算法来融合各情景信息,以缓解数据稀疏性。近年来,为了更深层次地挖掘用户偏好,相关工作主要利用图嵌入方法与深度学习来构建模型,从而提高推荐性能。以上的研究总结可为相关领域的研究者提供更好的借鉴,同时将前沿的技术应用到兴趣点推荐工作中值得探索。

#### 4 算法评价指标

兴趣点推荐系统利用各种推荐算法为用户生成最终的推荐列表,系统通过度量相关的评价指标对构建的算法进行评价,评价的结果反映了算法的有效性。与传统推荐使用的指标相似,在兴趣点推荐中,目前常用的预测指标包括准确率(precision)、召回率(recall)、F1值、平均绝对误差(mean absolute error, MAE)。定义分别如下:

$$precision@k = \frac{\sum_{u \in U} |R(u) \cap L(u)|}{\sum_{u \in U} |R(u)|} \quad (12)$$

$$recall@k = \frac{\sum_{u \in U} |R(u) \cap L(u)|}{\sum_{u \in U} |L(u)|} \quad (13)$$

$$F1 = \frac{2 \times recall \times precision}{recall + precision} \quad (14)$$

$$MAE = \frac{1}{N} \sum_{u,i} |r_{u,i} - \hat{r}_{u,i}| \quad (15)$$

其中,  $k$  表示推荐列表的个数;  $R(u)$  表示对应算法计算训练集后生成的推荐列表;  $L(u)$  表示用户  $u$  在测试集上真实的签到列表;  $r_{u,i}$  表示真实的评分;  $\hat{r}_{u,i}$  表示预测评分。

另外,每个用户推荐生成列表具有有序性,理想状态是准确率越高的兴趣点排序越靠前越好。因此,针对排序的结果,需通过度量其排序指标来评估算法的性能,常用的指标包括平均精度均值(mean average precision, MAP)和归一化折损累计增益(normalized discounted cumulative gain, NDCG)。两者的区别主要在于MAP考虑对象是二元相关性,即对象要么喜欢要么不喜欢,而NDCG主要通过实数的形式进行相关性比较。定义分别如下:

$$MAP@k = \frac{1}{M} \sum_{i=1}^M \frac{\sum_{j=1}^k (p(j) \times rel(j))}{N} \quad (16)$$

$$DCG_k = \sum_{j=1}^k \frac{2^{rel(j)} - 1}{\lg(j+1)} \quad (17)$$

$$NDCG@k = \frac{1}{M} \sum_{i=1}^M \frac{DCG_k}{iDCG_k} \quad (18)$$

其中,  $j$  表示排名;  $p(j)$  表示推荐生成列表中截止到  $j$  的准确率;  $rel(j)$  的值取决于用户是否有签到排名  $j$  的兴趣点,若有签到则值为1,否则为0。

推荐的效果取决于评价指标值的高低,对算法进行评估测量是推荐工作的最后流程。为了了解兴趣点推荐工作中各指标的应用情况,本文列举了几种重要算法采用的指标。同时为了综合了解算法的整体性能,将其对应文献所涉及的时间与空间复杂度进行了归纳,如表5所示。

由表5可知,precision和recall是应用最广的预

表5 几种代表算法的评价指标总结

Table 5 Summary of evaluation metrics of several algorithms

代表算法	precision	recall	F1	MAE	MAP	NDCG	时间复杂度	空间复杂度
LRT <sup>[14]</sup>	✓	✓					$O(mnd)$	N/A
ASMF <sup>[56]</sup>	✓	✓			✓		$O(mnd^2)$	N/A
UCGSMF <sup>[21]</sup>	✓	✓					$O((m+n)d^2 + Md)$	N/A
GSBPR <sup>[74]</sup>	✓	✓			✓	✓	$O(Tmd)$	N/A
APRA-SA <sup>[51]</sup>	✓	✓	✓	✓			$O(md + n^2)$	N/A
SPR <sup>[45]</sup>				✓			$O(Tn^3d)$	$O(mn + n^2)$
MANC <sup>[75]</sup>	✓	✓			✓	✓	N/A	N/A
ATST-LSTM <sup>[41]</sup>	✓	✓	✓				$O(mnd^2)$	N/A
Loc-Interest-LSTM <sup>[64]</sup>	✓	✓	✓				$O(TKn)$	$O(Kn)$

注:  $m$  表示用户的数量;  $n$  表示兴趣点的数量;  $d$  表示维度;  $M$  表示数据集大小;  $T$  表示迭代的数量;  $K$  表示兴趣主题的数量; N/A 表示相关文献未提及。

测指标,因为它们能够最直接反映出预测的推荐列表是否符合用户的喜好,所以获得广泛的应用。 $F1$ 作为 precision 和 recall 的调和平均值,通常用于评估算法的整体性能。MAE 能够反映预测评分与真实评分的差距,在文献[48,52]中,该指标主要用于对推荐结果进行误差评估,以更有效地评价推荐的准确性。MAP 与 NDCG 是经典的排序指标,在文献[74-75]中,为了综合评估排序的性能,结合了两种指标进一步说明算法的有效性。因此,在算法评价流程中,采用越多的预测和排序指标,以及结合适当的复杂度分析会增加算法的说服力。同时,进一步发掘更多的评估指标来验证算法的性能,是未来研究的重点内容。

## 5 面临的挑战及研究趋势

兴趣点推荐系统作为一个新兴的研究领域,近年来取得了较为丰硕的成果,但由于不同场景下推荐的差异性与多样性,导致推荐的难度增加,仍存在一些挑战和难点亟待解决。本文总结了未来可进一步探究的内容,概括来讲包括以下这些潜在的方向。

### (1) 数据来源问题

在基于位置社会网络的兴趣点推荐系统中,用户采用“签到”的方式与社交网络中的好友共享位置,从而产生签到数据。作为推荐工作的基础,对数据的挖掘与认知至关重要,然而用户的签到数据往往采用隐式的方式表达<sup>[76]</sup>。比如用户对地点的签到次数越高,可理解为用户偏好此地点,但用户签到的频率无固定的数据范围,增加了量化偏好值的难度,这与传统推荐系统显式打分的方法有所区别。另外,兴趣点推荐工作的数据集主要来源于一些公开网站<sup>[77-79]</sup>,但用户可能仅在海量的位置中留下稀疏的签到记录,增加了数据获取的难度,这是推荐工作面临的首要问题。

### (2) 融合多种影响因素的推荐

目前的兴趣点推荐工作主要针对用户及兴趣点两个维度的属性进行研究,如用户的社交关系、签到时间、兴趣点的内容及流行度等。如何进一步拓展影响用户决策的其他行为信息,从而辅助用户决策至关重要。比如,兴趣点推荐还可能受到用户自身的情感以及外界因素(如天气、交通)的影响,探究用户的情感行为及引入外界因素构建模型成为一项富有挑战的研究内容。

### (3) 跨领域推荐

跨领域推荐可融合来自不同领域的用户偏好

特征,进而根据每个用户自身特征进行个性化推荐,提高目标领域推荐的多样性与准确性。在兴趣点推荐工作中,存在数据稀疏问题与冷启动问题,若融合多个辅助领域的数据来为目标领域进行推荐,可有效解决兴趣点推荐中的冷启动问题。例如,已有工作在对图神经网络的应用中,对用户与兴趣点关系图的构建主要停留在单一的层面上,考虑如何从一个关系图过渡到其他的关系图,进而实现不同图神经网络框架间的数据迁移,是一个值得关注的问题。

### (4) 推荐结果的可解释性

推荐的可解释性指的是向推荐对象提供解释,使其理解推荐该项目的原因,为了使兴趣点推荐系统成为一个用户参与的交互系统,必须提高推荐结果的可解释性,从而提高推荐系统的有效性及用户的满意度。在对兴趣点推荐结果的解释过程中,不仅要考虑兴趣点的属性,还要关注属性可能随时间动态变化的特征。深度学习依靠其强大的表征能力被广泛应用到推荐系统,然而其深层神经网络被普遍认为是不可解释的。近年来备受关注的知识图谱方法为该问题带来了契机,它通过建立<实体,关系,属性>三元组来提高可解释性,然而知识图谱的大数据规模无法依据用户反馈进行实时更新,只能略微改善推荐的可解释性。目前对兴趣点推荐中可解释性问题的研究还比较少,探索一类能够实时交互更新的可解释性推荐方法值得研究。

### (5) 用户的隐私保护

为了提高推荐的性能,当前的兴趣点推荐工作需要从用户签到的历史记录与交互行为中充分挖掘用户的潜在偏好信息,包括对用户信息的收集、处理、存储和挖掘等,这在一定程度上威胁到用户的隐私信息。为此,现有的兴趣点推荐系统面临着较高的隐私风险,提高兴趣点推荐的性能与保护用户的隐私问题可能相悖。目前用来解决隐私保护问题的一类方法是向原始数据中添加噪音,该方法简单高效且易实现,然而过多的噪音会影响算法的有效性;另一类方法是采用加密技术,但效率较低且实用性不强;最近出现的联合学习是一种新的隐私保护学习方法,它不需要用户共享实时的签到信息,可通过离线的方式训练模型,适用性较强,但需要有足够的数据量。因此,如何应用相关技术在推荐的高精度要求与隐私保护间找到适当的平衡点,成为了兴趣点推荐系统研究的难点。

## 6 结束语

移动社交网络与推荐系统的融合, 助推了基于位置社交网络的兴趣点推荐系统的发展。兴趣点推荐利用用户的签到数据及相关的情景信息模拟用户的决策行为, 以挖掘用户潜在感兴趣的地点, 成为当前推荐系统领域较为活跃的方向之一。本文首先对现有的兴趣点推荐的研究现状进行了梳理、分类与归纳, 介绍了兴趣点推荐系统的相关理论与基本框架。接着围绕基本框架对影响兴趣点推荐的因素、推荐算法和算法评价三大核心内容进行概述, 并详细分析对比了各种代表性工作的研究内容和优缺点。最后对该领域难点问题和研究方向进行总结和展望, 提出一些潜在的发展方向与趋势, 希望能为兴趣点推荐领域的学者提供借鉴与帮助。

## 参考文献:

- [1] BARAL R, ZHU X L, IYENGAR S S, et al. ReEL: review aware explanation of location recommendation[C]//Proceedings of the 26th Conference on User Modeling, Adaptation and Personalization, Singapore, Jul 8-11, 2018. New York: ACM, 2018: 23-32.
- [2] RAVI L, SUBRAMANIASWAMY V, VARADHARAJAN V, et al. Efficient user profiling based intelligent travel recommender system for individual and group of users[J]. Mobile Networks and Applications, 2019, 24(3): 1018-1033.
- [3] KOREN Y, BELL R, VOLINSKY C. Matrix factorization techniques for recommender systems[J]. Computer, 2009, 42(8): 30-37.
- [4] ZHANG Z P, ZHANG Y, REN Y G. Employing neighborhood reduction for alleviating sparsity and cold start problems in user-based collaborative filtering[J]. Information Retrieval Journal, 2020, 23(4): 449-472.
- [5] XUE F, HE X N, WANG X, et al. Deep item-based collaborative filtering for top-n recommendation[J]. ACM Transactions on Information Systems, 2019, 37(3): 1-25.
- [6] 郭宁宁, 王宝亮, 侯永宏, 等. 融合社交网络特征的协同过滤推荐算法[J]. 计算机科学与探索, 2018, 12(2): 208-217.
- GUO N N, WANG B L, HOU Y H, et al. Collaborative filtering recommendation algorithm based on characteristics of social network[J]. Journal of Frontiers of Computer Science and Technology, 2018, 12(2): 208-217.
- [7] YE M, YIN P F, LEE W C, et al. Exploiting geographical influence for collaborative point-of-interest recommendation [C]//Proceedings of the 34th International ACM SIGIR Conference on Research and Development in Information Retrieval, Beijing, Jul 25-29, 2011. New York: ACM, 2011: 325-334.
- [8] YUAN Q, CONG G, MA Z Y, et al. Time-aware point-of-interest recommendation[C]//Proceedings of the 36th International ACM SIGIR Conference on Research and Development in Information Retrieval, Dublin, Jul 28-Aug 1, 2013. New York: ACM, 2013: 363-372.
- [9] ADOMAVICIUS G, TUZHILIN A. Toward the next generation of recommender systems: a survey of the state-of-the-art and possible extensions[J]. IEEE Transactions on Knowledge and Data Engineering, 2005, 17(6): 734-749.
- [10] SHIH D H, YEN D C, LIN H C, et al. An implementation and evaluation of recommender systems for traveling abroad [J]. Expert Systems with Applications, 2011, 38(12): 15344-15355.
- [11] KARDAN A A, EBRAHIMI M. A novel approach to hybrid recommendation systems based on association rules mining for content recommendation in asynchronous discussion groups[J]. Information Sciences, 2013, 219: 93-110.
- [12] GUO B, LI J, ZHENG V W, et al. CityTransfer: transferring inter- and intra-city knowledge for chain store site recommendation based on multi-source urban data[J]. Proceedings of the ACM on Interactive, Mobile, Wearable and Ubiquitous Technologies, 2018, 1(4): 1-23.
- [13] 焦旭, 肖迎元, 郑文广, 等. 基于位置的社交网络推荐技术研究进展[J]. 计算机研究与发展, 2018, 55(10): 2291-2306.
- JIAO X, XIAO Y Y, ZHENG W G, et al. Research progress of recommendation technology in location-based social networks[J]. Journal of Computer Research and Development, 2018, 55(10): 2291-2306.
- [14] GAO H J, TANG J L, HU X, et al. Exploring temporal effects for location recommendation on location-based social networks[C]//Proceedings of the 7th ACM Conference on Recommender Systems, Hong Kong, China, Oct 12-16, 2013. New York: ACM, 2013: 93-100.
- [15] ZHANG J D, CHOW C Y. iGSLR: personalized geo-social location recommendation—a kernel density estimation approach[C]//Proceedings of the 21st SIGSPATIAL International Conference on Advances in Geographic Information Systems, Orlando, Nov 5-8, 2013. New York: ACM, 2013: 324-333.
- [16] ZHANG J D, CHOW C Y. CoRe: exploiting the personalized influence of two-dimensional geographic coordinates for location recommendation[J]. Journal of Information Sciences, 2015, 293(1): 163-181.
- [17] 任星怡, 宋美娜, 宋俊德. 基于用户签到行为的兴趣点推荐[J]. 计算机学报, 2017, 40(1): 28-51.
- REN X Y, SONG M N, SONG J D. Point-of-interest reco-



- mmendation based on the user check-in behavior[J]. Chinese Journal of Computers, 2017, 40(1): 28-51.
- [18] SONG C, WEN J H, LI S. Personalized POI recommendation based on check-in data and geographical regional influence[C]//Proceedings of the 3rd International Conference on Machine Learning and Soft Computing, Da Lat, Jan 25-28, 2019. New York: ACM, 2019: 128-133.
- [19] ZHOU J J, LIU B, CHEN Y F, et al. UFC: a unified POI recommendation framework[J]. Arabian Journal for Science and Engineering, 2019, 44(11): 9321-9332.
- [20] 任星怡, 宋美娜, 宋俊德. 基于位置社交网络的上下文感知的兴趣点推荐[J]. 计算机学报, 2017, 40(4): 824-841.
- REN X Y, SONG M N, SONG J D. Context-aware point-of-interest recommendation in location-based social networks [J]. Chinese Journal of Computers, 2017, 40(4): 824-841.
- [21] 彭宏伟, 靳远远, 吕晓强, 等. 一种基于矩阵分解的上下文感知 POI 推荐算法 [J]. 计算机学报, 2019, 42(8): 1797-1811.
- PENG H W, JIN Y Y, LV X Q, et al. Context-aware POI recommendation based on matrix factorization[J]. Chinese Journal of Computers, 2019, 42(8): 1797-1811.
- [22] XIONG X, QIAO S J, HAN N, et al. Where to go: an effective point-of-interest recommendation framework for heterogeneous social networks[J]. Neurocomputing, 2020, 373: 56-69.
- [23] XING S N, LIU F A, WANG Q Q, et al. Content-aware point-of-interest recommendation based on convolutional neural network[J]. Applied Intelligence, 2019, 49(3): 858-871.
- [24] CHENG C, YANG H Q, KING I, et al. Fused matrix factorization with geographical and social influence in location-based social networks[C]//Proceedings of the 26th AAAI Conference on Artificial Intelligence, Toronto, Jul 22-26, 2012. Menlo Park: AAAI, 2012: 17-23.
- [25] 温彦, 马立健, 曾庆田, 等. 基于地理信息偏好修正和社交关系偏好隐式分析的 POI 推荐[J]. 数据分析与知识发现, 2019, 3(8): 30-40.
- WEN Y, MA L J, ZENG Q T, et al. POI recommendation based on geographic and social relationship preferences[J]. Data Analysis and Knowledge Discovery, 2019, 3(8): 30-40.
- [26] 夏英, 张金凤. 融合社交关系和局部地理因素的兴趣点推荐[J]. 计算机工程与应用, 2021, 57(15): 133-139.
- XIA Y, ZHANG J F. POI recommendation fusing social relations and local geographic factors[J]. Computer Engineering and Applications, 2021, 57(15): 133-139.
- [27] LIU T C, LIAO J X, WU Z G, et al. Exploiting geographical-temporal awareness attention for next point-of-interest recommendation[J]. Neurocomputing, 2020, 400: 227-237.
- [28] LIAN D F, ZHAO C, XIE X, et al. GeoMF: joint geographical modeling and matrix factorization for point-of-interest recommendation[C]//Proceedings of the 20th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, New York, Aug 24-27, 2014. New York: ACM, 2014: 831-840.
- [29] RAHMANI H A, ALIANNEJADI M, AHMADIAN S, et al. LGLMF: local geographical based logistic matrix factorization model for POI recommendation[C]//LNCS 12004: Proceedings of the 15th Asia Information Retrieval Societies Conference on Information Retrieval Technology, Hong Kong, China, Nov 7-9, 2019. Cham: Springer, 2020: 66-78.
- [30] QIAN X M, FENG H, ZHAO G S, et al. Personalized recommendation combining user interest and social circle[J]. IEEE Transactions on Knowledge and Data Engineering, 2014, 26(7): 1763-1777.
- [31] ZHANG Z Y, LIU Y, ZHANG Z J, et al. Fused matrix factorization with multi-tag, social and geographical influences for POI recommendation[J]. World Wide Web, 2019, 22(3): 1135-1150.
- [32] ZHU J H, WANG C, GUO X, et al. Friend and POI recommendation based on social trust cluster in location-based social networks[J]. EURASIP Journal on Wireless Communications and Networking, 2019(1): 89.
- [33] XU C H, DING A S, ZHAO K D. A novel POI recommendation method based on trust relationship and spatial-temporal factors[J]. Electronic Commerce Research and Applications, 2021, 48: 101060.
- [34] ZHU J H, GUO X. Deep neural model for point-of-interest recommendation fused with graph embedding representation [C]//LNCS 11604: Proceedings of the 14th International Conference on Wireless Algorithms, Systems, and Applications, Honolulu, Jun 24-26, 2019. Cham: Springer, 2019: 495-506.
- [35] QIAO Y, LUO X, LI C, et al. Heterogeneous graph-based joint representation learning for users and POIs in location-based social network[J]. Information Processing & Management, 2020, 57(2): 102151.
- [36] CHEN L, YING Y K, LYU D, et al. A multi-task embedding based personalized POI recommendation method[J]. CCF Transactions on Pervasive Computing and Interaction, 2021, 3(3): 253-269.
- [37] YING H C, WU J, XU G D, et al. Time-aware metric embedding with asymmetric projection for successive POI recommendation[J]. World Wide Web, 2019, 22(5): 2209-2224.
- [38] MA Y X, GAN M X. Exploring multiple spatio-temporal information for point-of-interest recommendation[J]. Soft

- Computing, 2020, 24: 18733-18747.
- [39] YIN M, LIU Y, ZHOU X, et al. A fuzzy clustering based collaborative filtering algorithm for time-aware POI recommendation[J]. Journal of Physics: Conference Series, 2021, 1746(1): 012037.
- [40] LU Y S, HUANG J L. GLR: a graph-based latent representation model for successive POI recommendation[J]. Future Generation Computer Systems, 2020, 102: 230-244.
- [41] HUANG L W, MA Y T, WANG S B, et al. An attention-based spatiotemporal LSTM network for next POI recommendation[J]. IEEE Transactions on Services Computing, 2021, 14(6): 1585-1597.
- [42] WANG H L, LI P Y, LIU Y, et al. Towards real-time demand-aware sequential POI recommendation[J]. Information Sciences, 2021, 547: 482-497.
- [43] WU Y, LI K, ZHAO G, et al. Personalized long- and short-term preference learning for next POI recommendation[J]. IEEE Transactions on Knowledge and Data Engineering, 2022, 34(4): 1944-1957.
- [44] CHEN L, ZHANG L, CAO S S, et al. Personalized itinerary recommendation: deep and collaborative learning with textual information[J]. Expert Systems with Applications, 2020, 144: 113070.
- [45] ZHAO G, LOU P, QIAN X, et al. Personalized location recommendation by fusing sentimental and spatial context [J]. Knowledge-Based Systems, 2020, 196: 105849.
- [46] ZHANG Z B, ZOU C, DING R F, et al. VCG: exploiting visual contents and geographical influence for point-of-interest recommendation[J]. Neurocomputing, 2019, 357: 53-65.
- [47] CONTRACTOR D, GOEL S, SINGLA P. Joint spatio-textual reasoning for answering tourism questions[C]//Proceedings of the 2021 Web Conference, Ljubljana, Apr 19-23, 2021. New York: ACM, 2021: 1978-1989.
- [48] SÁNCHEZ VILLEGAS D, ALETRAS N. Point-of-interest type prediction using text and images[J]. arXiv:2109.00602, 2021.
- [49] YANG Y, DUAN Y Q, WANG X Z, et al. Hierarchical multi-clue modelling for POI popularity prediction with heterogeneous tourist information[J]. IEEE Transactions on Knowledge and Data Engineering, 2019, 31(4): 757-768.
- [50] YAO Z J, FU Y J, LIU B, et al. POI recommendation: a temporal matching between POI popularity and user regularity[C]//Proceedings of the IEEE 16th International Conference on Data Mining, Barcelona, Dec 12-15, 2016. Washington: IEEE Computer Society, 2016: 549-558.
- [51] SI Y L, ZHANG F Z, LIU W Y. An adaptive point-of-interest recommendation method for location-based social networks based on user activity and spatial features[J]. Knowledge-Based Systems, 2019, 163: 267-282.
- [52] YU D J, XU K H, WANG D J, et al. Point-of-interest recommendation based on user contextual behavior semantics [J]. International Journal of Software Engineering and Knowledge Engineering, 2019, 29(11/12): 1781-1799.
- [53] DAVTALAB M, ALESHEIKH A A. A POI recommendation approach integrating social spatio-temporal information into probabilistic matrix factorization[J]. Knowledge and Information Systems, 2021, 63(1): 65-85.
- [54] YU D J, WANYAN W B, WANG D J. Leveraging contextual influence and user preferences for point-of-interest recommendation[J]. Multimedia Tools and Applications, 2021, 80(1): 1487-1501.
- [55] YUAN H, XU J, ZHENG N, et al. PRPOIR: exploiting the region-level interest for POI recommendation[C]//Proceedings of the 32nd IEEE International Conference on Tools with Artificial Intelligence, Baltimore, Nov 9-11, 2020. Piscataway: IEEE, 2020: 59-66.
- [56] LI H, GE Y, HONG R C, et al. Point-of-interest recommendations: learning potential check-ins from friends[C]//Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, San Francisco, Aug 13-17, 2016. New York: ACM, 2016: 975-984.
- [57] RAHMANI H A, ALIANNEJADI M, BARATCHI M, et al. Joint geographical and temporal modeling based on matrix factorization for point-of-interest recommendation[J]. Advances in Information Retrieval, 2020, 12035: 205-219.
- [58] LU Y S, HUANG J L. GLR: a graph-based latent representation model for successive POI recommendation[J]. Future Generation Computer Systems, 2020, 102: 230-244.
- [59] HU X J, XU J J, WANG W Q, et al. A graph embedding based model for fine-grained POI recommendation[J]. Neurocomputing, 2021, 428: 376-384.
- [60] CHRISTOFORIDIS G, KEFALAS P, PAPADOPOULOS A N, et al. RELINE: point-of-interest recommendations using multiple network embeddings[J]. Knowledge and Information Systems, 2021, 63(4): 791-817.
- [61] XING S, LIU F, ZHAO X, et al. Points-of-interest recommendation based on convolution matrix factorization[J]. Applied intelligence, 2018, 48(8): 2458-2469.
- [62] 冯浩, 黄坤, 李晶, 等. 基于深度学习的混合兴趣点推荐算法[J]. 电子与信息学报, 2019, 41(4): 880-887.
- FENG H, HUANG K, LI J, et al. Hybrid point of interest recommendation algorithm based on deep learning[J]. Journal of Electronics & Information Technology, 2019, 41(4):

- 880-887.
- [63] XIA B, LI Y, LI Q M, et al. Attention-based recurrent neural network for location recommendation[C]//Proceedings of the 12th International Conference on Intelligent Systems and Knowledge Engineering, Nanjing, Nov 24-26, 2017. Piscataway: IEEE, 2017: 1-6.
- [64] CHEN M, LI W Z, QIAN L, et al. Next POI recommendation based on location interest mining with recurrent neural networks[J]. Journal of Computer Science and Technology, 2020, 35(3): 603-616.
- [65] SUN K, QIAN T, CHEN T, et al. Where to go next: modeling long- and short-term user preferences for point-of-interest recommendation[C]//Proceedings of the 34th AAAI Conference on Artificial Intelligence, the 32nd Innovative Applications of Artificial Intelligence Conference, the 10th AAAI Symposium on Educational Advances in Artificial Intelligence, New York, Feb 7-12, 2020. Menlo Park: AAAI, 2020: 214-221.
- [66] HUANG C M, WU C Y. The point of interest (POI) recommendation for mobile digital culture heritage (M-DCH) based on the behavior analysis using the recurrent neural networks (RNN) and user-collaborative filtering[J]. Journal of Internet Technology, 2021, 22(4): 821-833.
- [67] ZHONG T, ZHANG S, ZHOU F, et al. Hybrid graph convolutional networks with multi-head attention for location recommendation[J]. World Wide Web, 2020, 23(6): 3125-3151.
- [68] ZHANG J, LIU X, ZHOU X, et al. Leveraging graph neural networks for point-of-interest recommendations[J]. Neurocomputing, 2021, 462: 1-13.
- [69] KANG Y, CHEN J, CAO Y, et al. A higher-order graph convolutional network for location recommendation of an air-quality-monitoring station[J]. Remote Sensing, 2021, 13(8): 1600.
- [70] HUANG L, MA Y, LIU Y, et al. DAN-SNR: a deep attentive network for social-aware next point-of-interest recommendation[J]. ACM Transactions on Internet Technology, 2020, 21(1): 1-27.
- [71] LUO Y T, LIU Q, LIU Z C. STAN: spatio-temporal attention network for next location recommendation[C]//Proceedings of the 2021 Web Conference, Ljubljana, Apr 19-23, 2021. New York: ACM, 2021: 2177-2185.
- [72] 张松慧, 熊汉江. 融合神经网络和泊松分解的兴趣点推荐算法[J]. 计算机工程与应用, 2020, 56(21): 176-186.
- ZHANG S H, XIONG H J. Point-of-interest recommendation algorithm based on Poisson factorization and neural network[J]. Computer Engineering and Applications, 2020, 56(21): 176-186.
- [73] XIE M, YIN H Z, WANG H, et al. Learning graph-based POI embedding for location-based recommendation[C]//Proceedings of the 25th ACM International Conference on Information and Knowledge Management, Indianapolis, Oct 24-28, 2016. New York: ACM, 2016: 15-24.
- [74] GAO R, LI J, DU B, et al. Exploiting geo-social correlations to improve pairwise ranking for point-of-interest recommendation[J]. China Communications, 2018, 15(7): 180-201.
- [75] CHANG L, CHEN W, HUANG J B, et al. Exploiting multi-attention network with contextual influence for point-of-interest recommendation[J]. Applied Intelligence, 2021, 51(4): 1904-1917.
- [76] ZHU J H, GUO X. Deep neural model for point-of-interest recommendation fused with graph embedding representation[C]//LNCS 11604: Proceedings of the 14th International Conference on Wireless Algorithms, Systems, and Applications, Honolulu, Jun 24-26, 2019. Cham: Springer, 2019: 495-506.
- [77] GAO H J, TANG J L, HU X, et al. Content-aware point of interest recommendation on location-based social networks [C]//Proceedings of the 29th AAAI Conference on Artificial Intelligence, Austin, Jan 25-30, 2015. Menlo Park: AAAI, 2015: 1721-1727.
- [78] CHO E, MYERS S A, LESKOVEC J. Friendship and mobility: user movement in location-based social networks[C]//Proceedings of the 17th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, San Diego, Aug 21-24, 2011. New York: ACM, 2011: 1082-1090.
- [79] YELP. Challenge data set[EB/OL]. (2014-04-25)[2021-10-25]. [http://www.yelp.com/dataset\\_challenge](http://www.yelp.com/dataset_challenge).



陈江美(1995—),女,福建南平人,博士研究生,主要研究方向为商务智能、数据挖掘等。

**CHEN Jiangmei**, born in 1995, Ph.D. candidate. Her research interests include business intelligence, data mining, etc.



张文德(1962—),男,福建福州人,博士,教授,主要研究方向为信息化管理、知识产权等。

**ZHANG Wende**, born in 1962, Ph.D., professor. His research interests include information management, intellectual property, etc.