

融合社交关系和局部地理因素的兴趣点推荐

夏 英, 张金凤

重庆邮电大学 计算机科学与技术学院, 重庆 400065

摘 要: 兴趣点(Point-Of-Interest, POI)推荐是基于位置社交网络(Location-Based Social Network, LBSN)中一项重要的个性化服务,可以帮助用户发现其感兴趣的POI,提高信息服务质量。针对POI推荐中存在的稀疏性问题,提出一种融合社交关系和局部地理因素的POI推荐算法。根据社交关系中用户间的共同签到和距离关系度量用户相似性,并基于用户的协同过滤方法构建社交影响模型。为每个用户划分一个局部活动区域,通过对区域内POIs间的签到相关性分析,建立局部地理因素影响模型。基于加权矩阵分解挖掘用户自身偏好,并融合社交关系和局部地理因素进行POI推荐。实验表明,所提出的POI推荐算法相比其他方法具有更高的准确率和召回率,能够有效缓解数据稀疏性问题,提高推荐质量。

关键词: 位置社交网络;兴趣点推荐;社交关系;局部地理因素;加权矩阵分解

文献标志码: A **中图分类号:** TP311 **doi:** 10.3778/j.issn.1002-8331.2007-0172

POI Recommendation Fusing Social Relations and Local Geographic Factors

XIA Ying, ZHANG Jinfeng

School of Computer Science and Technology, Chongqing University of Posts and Telecommunications, Chongqing 400065, China

Abstract: POI recommendation is an important personalized service in Location-Based Social Network(LBSN), which can help users discover POIs and improve the quality of information services. Aiming at the problem of data sparsity in POI recommendation, this paper proposes a POI recommendation algorithm combining social relationship and local geographic factors. This algorithm measures user similarity based on the common check-in and distance relationships among users in the social relationship, and builds a social model through user collaborative filtering. A local activity area for each user is divided, and the sign-in correlation is analyzed to establish a local geographic factor model. Based on weighted matrix decomposition, users' own preferences are mined, and social relationships and local geographic factors for POI recommendation are integrated. Experiments on the Gowalla dataset show that the proposed POI recommendation algorithm has higher accuracy and recall rate than other methods, which can effectively alleviate the problem of data sparsity and improve recommendation performance.

Key words: Location-Based Social Networks(LBSN); Point-Of-Interest(POI) recommendation; social relationship; local geographic factors; weighted matrix factorization

目前,随着智能手机、移动互联网等技术的发展,LBSN得到广泛应用,如国外的Gowalla、Foursquare,国内的大众点评、美团等。在LBSN平台,用户可对当前访问的POI(如餐厅、书店、旅游景点等)进行签到、评论等操作,并能与社交好友分享自己的签到信息。在LBSN除了用户签到信息,还包含社交关系、兴趣点、用户评论等海量数据,充分挖掘这些数据,可以更好地分析用户的签到行为,把握用户群体兴趣特征和访问规

律,有利于提高个性化POI推荐服务质量。

在LBSN平台,POI的规模庞大且分布广泛,而每个用户访问并签到过的POI往往很少,这使得用户签到数据十分稀疏,给POI推荐带来挑战。

针对用户签到数据的稀疏性问题,本文提出基于社交关系和局部地理因素的POI推荐算法,通过融合社交关系、地理位置信息来丰富有效数据,提高推荐质量。本文的主要贡献有以下三点:

基金项目: 国家自然科学基金(41971365);重庆市基础与前沿研究计划(cstc2019jcyjmsxm0131);重庆市研究生科研创新项目(CYS20277)。

作者简介: 夏英(1972—),女,博士,教授,CCF会员,研究领域为数据库、数据挖掘、云计算;张金凤(1995—),通信作者,女,硕士,研究领域为社交网络分析、推荐系统、数据挖掘,E-mail:381877677@qq.com。

收稿日期: 2020-07-10 **修回日期:** 2021-05-28 **文章编号:** 1002-8331(2021)15-0133-07

(1)在构建社交关系影响模型时,综合考虑用户间的共同签到和距离关系,提出一种用户相似性度量方法,减少相似性计算误差。

(2)在构建地理因素影响模型时,通过为每个用户划分一个局部活动区域,分析用户所属区域内尚未访问 POIs 间的签到相关性,更加充分地剖析出每个用户签到的地理偏好。

(3)在进行兴趣点推荐时,将上述考虑的社交关系和局部地理因素融合到加权矩阵分解模型中,构建一个更加符合用户偏好的 POI 推荐模型,在一定程度上缓解了数据稀疏性问题。实验表明,本文所提出的算法具有更高的准确率和召回率。

1 相关工作

POI 推荐是 LBSN 中重要的个性化服务,旨在为用户推荐符合他们兴趣但尚未访问过的 POI 列表。目前,针对位置社交网络的 POI 推荐已展开大量的研究工作,一些特定场景的应用也开始大量涌现,如餐厅推荐^[1]、旅游路线推荐^[2]等。

目前,大多数的 POI 推荐都是通过用户签到数据结合丰富的上下文信息来缓解数据稀疏性,挖掘用户对尚未访问 POIs 的偏好程度。如 Cheng 等人^[3]采用多中心高斯分布来建模 POIs 间距离分布,并结合社交关系进行 POI 推荐。Zhang 等人^[4]为避免所有用户采用统一分布造成的误差,采用核密度估计模拟任意两个 POIs 间的距离分布,构建地理因素影响模型。Zhang 等人^[5]从位置序列中挖掘顺序模式,并将序列影响、社交影响和地理因素影响融合在统一的推荐框架中。Yali 等人^[6]在基于朋友协同过滤基础上,综合考虑社交关系和地理位置特征,提出个性化的兴趣点推荐模型。Zhang 等人^[7]对标签、社交和地理因素分别进行建模,并将它们融合到一种矩阵分解方法中。Zhang 等人^[8]利用 BPR 模型对矩阵分解进行优化,并结合用户社交关系和地理位置信息进行 POI 推荐。

除此之外,也有很多研究利用其他上下文信息进行 POI 推荐,如 Gao 等人^[9]将一天划分为多个时间段,分别构建不同时间段下的 User-POI 签到矩阵,然后使用矩阵分解法获取不同时间段的用户偏好。Zhang 等人^[10]对用户评论进行语义分析和情感计算,根据用户的情感倾向预测用户偏好。Wu 等人^[11]将 POI 流行度特征融入基于用户协同过滤方法中,并结合社交关系和地理因素进行 POI 推荐。

尽管通过融合丰富的上下文信息可以有效缓解数据稀疏性问题,但现有融合上下文信息的 POI 推荐算法中仍存在以下一些问题:在研究社交关系影响时,用户相似性影响因素选取往往比较单一,对于那些拥有较少

签到信息的用户难以构建社交影响模型;在分析地理因素影响时,现有计算全局 POIs 间地理相关性的方法不能充分剖析每个用户的地理偏好。因此,本文提出融合社交关系和局部地理因素的 POI 推荐算法,可以有效地提高推荐的准确率和召回率。

2 兴趣点推荐模型

POI 推荐的任务是给用户推荐一个其感兴趣但尚未访问过的 POIs 列表。本章通过深入分析社交关系和地理因素对用户签到行为的影响,构建更加符合用户偏好的 POI 推荐模型。

2.1 相关符号及定义

为方便后续讨论,表 1 给出了相关符号及其含义。同时,对签到矩阵和签到热点进行了定义。

表 1 相关符号描述

Table 1 Relevant Symbols description

符号	相关描述
U, I	所有用户集合,所有 POI 集合
u, i	用户 $u \in U$, POI $i \in I$
R	用户签到矩阵
C	签到矩阵 R 对应的 0,1 矩阵
S	用户对 POI 的社交偏好矩阵
G	用户对 POI 的地理偏好矩阵
E	用户对 POI 的最终偏好矩阵
P	用户隐藏特征矩阵
Q	POI 隐藏特征矩阵
K	隐藏特征矩阵维度
W	签到矩阵 R 对应的权重矩阵

定义 1(签到矩阵) 根据用户历史签到记录,构建签到矩阵 $R_{|U| \times |I|}$,矩阵中每个元素 r_{ui} 表示用户 u 对 POI i 的签到次数。

定义 2(签到热点) 用户 u 签到次数最高的 POI。

2.2 社交关系影响模型的构建

在 LBSN 中,用户的签到行为在一定程度上受到其社交关系的影响,进而促使用户访问一些未去过的 POIs。例如,在日常生活中去过一个体验很好的餐厅或书店后,很可能会邀请或推荐自己的朋友前去,这些都可能使得用户在相同的 POI 产生共同签到,社交用户间存在一定的行为相似性。因此,考虑用户的社交关系对用户签到行为的影响有利于提高 POI 推荐质量。

对于用户尚未访问过的 POIs,本文使用基于用户的协同过滤方法^[12]计算社交关系信息对用户签到行为的影响程度,其计算公式如下:

$$s_{ui} = \frac{\sum_{v \in F_u} sim_{uv} \times c_{vi}}{\sum_{v \in F_u} sim_{uv}} \quad (1)$$

其中, c_{vi} 的定义如下:

$$c_{vi} = \begin{cases} 1, & r_{vi} > 0 \\ 0, & r_{vi} = 0 \end{cases} \quad (2)$$

其中, s_{ui} 表示用户 u 对 POI i 的偏好程度。 F_u 表示用户 u 在社交网络上的所有朋友集合, 用户 v 是用户 u 的社交好友, c_{vi} 表示好友 v 对 POI i 的签到情况, sim_{uv} 表示用户 u 和 v 的相似度。

对于式(1)中的用户相似度 sim_{uv} , 不同的研究采用的方法不同^[3-6]。大多数研究中, 只考虑了基于共同签到的用户相似度, 这对那些拥有较少签到信息用户无法有效计算其社交偏好。因此, 本文考虑在以往基于共同签到的相似性研究基础上, 同时通过用户间距离关系来度量用户间的兴趣差异, 减小用户相似度的计算误差。

一方面, 通常认为用户间的共同签到越多, 他们的偏好就越相似。在基于行为相关性的相似性度量方法中, Jaccard 方法^[13]在计算效率和推荐准确率上效果更好, 基于 Jaccard 方法计算用户签到相似度公式如下:

$$sim_c = \frac{|R_u \cap R_v|}{|R_u \cup R_v|} \quad (3)$$

其中, R_u 和 R_v 分别表示用户 u 和 v 签到的 POIs 集合。

另一方面, 考虑到相距较近的用户拥有更多的共享兴趣点, 会产生较多的共同签到。因此, 对于距离越近的用户, 其签到行为的相似度越高。本文通过改进 Sigmod 函数计算用户距离相似度。

Sigmod 函数是常见的 S 型函数, 公式定义如下:

$$S(x) = \frac{1}{1 + e^{-x}} \quad (4)$$

该函数连续、光滑、严格单调, 关于点 $(0, 0.5)$ 中心对称, 在区间 $[-\infty, +\infty]$ 上呈非线性增长。基于上述假设中距离相似度随着用户间距离应呈递减状态, 因此考虑改进 Sigmod 函数来衡量基于用户距离的相似度, 改进后的用户距离相似度计算公式如下:

$$sim_d = \frac{2}{1 + e^{dis(u,v)}} \quad (5)$$

其中, $dis(u,v)$ 表示用户 u 与 v 间的距离, 其根据用户签到热点的经纬度信息, 利用 Haversin e 方法^[14]计算得出。计算公式如下:

$$hav\left(\frac{dis(u,v)}{R}\right) = hav(\varphi_2 - \varphi_1) + \cos \varphi_1 \cdot \cos \varphi_2 \cdot hav(\sigma_2 - \sigma_1) \quad (6)$$

$$hav(\theta) = \frac{1 - \cos \theta}{2} \quad (7)$$

其中, R 为地球半径, φ_1 和 φ_2 分别表示用户 u 和 v 签到热点的纬度, σ_1 和 σ_2 分别表示用 u 和 v 签到热点的经度。

综合以上设计, 本文对用户签到相似度和距离相似度行线性加权, 得到用户 u 和 v 的最终相似度, 计算公式如下:

$$sim_{uv} = (1 - \alpha)sim_c + \alpha sim_d \quad (8)$$

其中, α 为调节用户签到相似度和距离相似度影响权重的参数。

将式(8)代入式(1)即可得到在社交关系影响下用户对兴趣点的社交偏好矩阵 S 。

2.3 局部地理因素影响模型的构建

在位置社交网络中, 地理位置信息是其特有的语境信息, 是提升 POI 推荐质量的重要因素。目前, 考虑地理因素影响的模型主要是通过分析用户所有签到 POIs 的分布情况, 通过 POIs 间距离关系计算用户对 POIs 的签到概率, 如常用的高斯分布^[3]及核密度估计^[4]等。为了进一步研究地理因素的影响, 这里发现用户签到呈现出空间聚类现象^[15], 表明用户喜欢访问邻近 POIs, 如用户去某个城市旅行, 往往会对相邻区域集中的 POIs 都进行访问, 邻近 POIs 间的签到情况具有一定的关联性^[16]。因此, 本文考虑为每个用户划分一个局部活动区域, 充分剖析区域内尚未访问 POIs 间的签到相关性, 构建更加符合用户偏好的局部地理因素影响模型。

步骤1 划分用户活动区域

首先, 找到用户 u 的签到热点, 然后为用户 u 划分一个距离签到热点半径为 β 的局部活动区域。

步骤2 寻找区域内用户尚未访问的 POIs

在步骤1所划分用户活动区域内, 寻找用户 u 尚未访问的 POIs 集合, 分析与集合中 POI i 相距小于 γ 的邻居 POIs 的签到情况。

步骤3 计算地理偏好程度

研究发现, 用户往往会对邻近 POIs 进行集中访问, 针对邻近 POIs 的签到影响已展开相关研究^[16]。其中, Hossein 等人^[17]认为用户对邻近 POIs 的签到数量会对用户 u 签到 POI i 产生一定影响, 并构建出一个更加符合用户偏好的地理偏好模型。因此, 本文根据邻居 POIs 的签到情况, 采用文献[17]中的地理偏好定义, 计算用户 u 对 POI i 的签到概率, 公式如下:

$$g_{ui} = 1 - \frac{N_i^u}{|L_u|} \quad (9)$$

其中, N_i^u 表示用户 u 对 POI i 所有邻居 POIs 的签到数量, L_u 表示用户 u 曾访问过的所有 POIs 集合。

2.4 融合社交关系和局部地理因素的兴趣点推荐模型

2.4.1 基础模型

在 LBSN 中, 用户社交关系、地理位置等上下文信息都会影响用户的签到行为, 但最主要的是从用户历史签到数据中反映出来的用户自身偏好。在 POI 推荐中, 矩阵分解技术^[18]常用于挖掘用户的自身偏好。但由于 User-POI 签到矩阵中只能观察到用户访问过的 POIs, 对

于那些用户尚未访问过的 POIs 会产生大量的缺失项, 因此无法使用一般的矩阵分解技术来构建用户自身偏好模型。Hu 等人^[19]首次在大规模隐式数据上提出加权矩阵分解 (Weighted Matrix Factorization, WMF) 模型, 该模型通过对用户已访问的 POIs 分配较大权重, 对尚未访问的 POIs 分配一个较小权重来解决 User-POI 签到矩阵中存在的缺失项问题。

在 POI 推荐中, WMF 方法将 User-POI 签到矩阵分解为两个低维隐藏特征矩阵 $P_{m \times k}$ 和 $Q_{n \times k}$, 用户对 POI 的自身偏好矩阵即为两个隐藏特征矩阵的内积。本文基于 WMF 模型构建用户自身偏好模型, 其目标函数定义如下:

$$f = \sum_{u=1}^{|U|} \sum_{i=1}^{|I|} w_{ui} (c_{ui} - p_u^T q_i)^2 + \lambda (\|p_u\|^2 + \|q_i\|^2) \quad (10)$$

$$c_{ui} = \begin{cases} 1, & r_{ui} > 0 \\ 0, & r_{ui} = 0 \end{cases} \quad (11)$$

其中, p_u 和 q_i 分别表示用户 u 与 POI i 对应的隐特征向量, λ 表示正则化系数。 w_{ui} 表示每个用户签到次数 r_{ui} 对应的权重, 本文采用文献[20]中权重设置方法, 加权矩阵 w 的权重系数设置如下:

$$w_{ui} = 1 + \ln(1 + r_{ui}/\varepsilon) \quad (12)$$

其中, ε 是用来控制权重系数随用户访问 POI 次数增长的速率。

2.4.2 模型融合

在 2.4.1 节中, WMF 模型根据用户的签到频次信息提取用户对 POI 的自身偏好, 但没有考虑社交关系和地理位置等影响因素。本文在 WMF 模型上进行改进, 将上述考虑的社交关系和局部地理信息融合到 WMF 模型中, 构建一个更加符合用户偏好的 POI 推荐模型 SLGMF。该模型的目标函数如式(13)所示:

$$f = \sum_{u=1}^{|U|} \sum_{i=1}^{|I|} w_{ui} (c_{ui} - e_{ui})^2 + \lambda (\|p_u\|^2 + \|q_i\|^2) \quad (13)$$

$$e_{ui} = p_u^T q_i + s_{ui} + g_{ui} \quad (14)$$

其中, e_{ui} 表示用户 u 对 POI i 的最终偏好, $\|p_u\|^2$ 和 $\|q_i\|^2$ 分别表示用户 u 和 POI i 的正则化项, 加入目的是为了以防过拟合。

本文目标函数采用交替最小二乘法进行优化, 其主要思想是先依次固定矩阵 P , 优化矩阵 Q , 然后再固定矩阵 Q , 优化矩阵 P , 反复交替, 不断修正 p 和 q 分量, 获得最优矩阵 P 和矩阵 Q 。

SLGMF 模型的构建如算法 2 所示。

算法 2 SLGMF 模型构建

输入: 用户集 U , 用户签到集 R , 用户社交信息, 地理位置信息

输出: 为用户推荐的 Top-N POIs 列表

1. for each $u \in U$ do
2. for each $i \in I$ do
3. 由式(1)计算社交偏好程度 s_{ui}
4. 由式(9)计算地理偏好程度 g_{ui}
5. 由式(12)计算权重系数 w_{ui}
6. End for
7. End for
8. for each $u \in U$ do
9. 更新矩阵 P
10. End
11. for each $i \in I$ do
12. 更新矩阵 Q
13. End
14. 由式(14)计算用户对 POI 的最终偏好矩阵 E
15. 根据矩阵元素 e_{ui} 排序, 为用户推荐 POIs 列表

3 实验评估

3.1 数据集

实验选取数据集 Gowalla^[21], Gowalla 收集了 2009 年 2 月至 10 月期间的所有签到数据、用户社交关系和 POI 信息。为使实验数据更加有效, 将数据集中用户和 POI 签到数量少于 15 条的低价值数据去除。处理后的标准数据集共有 5 628 个用户, 31 803 个 POIs 和 620 683 条签到记录, 以及 46 001 条社交关系。

3.2 评价指标

实验选取常用的准确率 (Precision) 和召回率 (Recall) 作为评价指标来衡量推荐算法的性能, 其定义分别如下:

$$Precision = \frac{1}{|U|} \sum_{u=1}^{|U|} \frac{|R_u \cap T_u|}{|R_u|} \quad (15)$$

$$Recall = \frac{1}{|U|} \sum_{u=1}^{|U|} \frac{|R_u \cap T_u|}{|T_u|} \quad (16)$$

其中, $|U|$ 表示用户数量, R_u 表示为用户 u 推荐的 POIs 列表, T_u 表示用户 u 曾访问过的 POIs 列表。

3.3 对比方法与参数设置

为了验证所提 SLGMF 算法的性能, 实验选取两种均融合社交关系和地理因素的 POI 推荐算法: MGMPFM^[3] 和 LORE^[5]。另外, 为了考察不同因素对 POI 推荐的影响, 本文将 SLGMF 算法拆分为仅融合社交关系的推荐算法 S-MF 和仅融合局部地理因素的推荐算法 LG-MF, 并进行自身对比。

MGMPFM: 利用多中心高斯模型建模地理因素影响, 在概率矩阵分解基础上融合社交和地理位置信息进行 POI 推荐。

LORE: 从用户签到的位置序列中挖掘出序列模式, 并融合社交和地理因素进行 POI 推荐。

S-MF:本文提出的模型,仅融合社交关系信息的推荐算法。

LG-MF:本文提出的模型,仅融合地理位置信息的推荐算法。

SLGMF:本文提出的模型,基于加权矩阵分解,综合考虑社交关系和局部地理因素的推荐算法。

在参数设置上,所选用对比模型应尽量与原文献保持一致,使各个算法性能达到最优。对于本文提出的SLGMF模型,分别设置隐藏特征矩阵维度 $K=25$,用户相似性影响因子 $\alpha=0.6$,地理因素影响因子 $\beta=30$, $\gamma=12$,上述参数的取值使得推荐效果达到最优。另外,地球半径 R 取平均值为6 371。

3.4 实验结果与分析

本文在相同数据集上对各个POI推荐算法进行Top- N ($N=5, 10, 15, 20, 25, 30$)推荐,图1和图2展示了Top- N 推荐的准确率和召回率。可以观察到准确率随着 N 的增大而减小,召回率随着 N 的增大而增大。这是由于返回的POIs越多,越有可能发现更多用户愿意访问的POIs。




图1 推荐的准确率

Fig.1 Recommendation precision

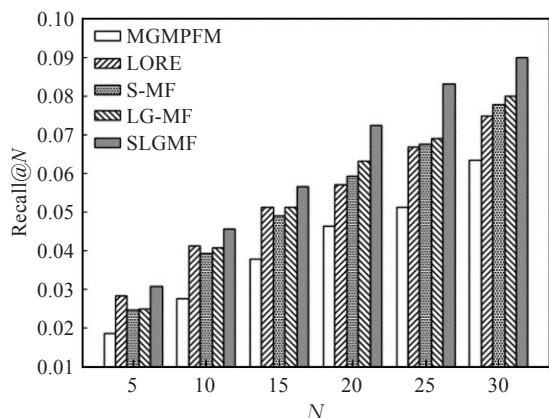


图2 推荐的召回率

Fig.2 Recommendation recall

图1和图2可以看出,对比MGMPFM和LORE这两种均融合社交关系和地理因素的POI推荐算法,无论 N

取何值,SLGMF算法在准确率和召回率上均有所提升,表明了本文所提出SLGMF算法的有效性。

另外,本文将SLGMF模型拆分为仅融合社交信息的POI推荐模型和仅融合地理位置信息的POI推荐模型,通过实验分析融合单一上下文信息的推荐效果,结果如图1和图2所示。当为用户进行Top-5推荐时,在准确率上,SLGMF算法相对S-MF算法提升了14.6%,相对LG-MF算法提升了11.2%。在召回率上,SLGMF算法相对于S-MF算法提升了24.3%,相对于LG-MF算法提升了22.8%。这说明本文在加权矩阵分解基础上融合多种上下文信息,确实可以有效地缓解数据稀疏性问题,提高推荐性能,并且融入有效的上下文信息越多,推荐效果越好。除此之外,对比S-MF和LG-MF算法可以发现,仅融合地理因素的LG-MF推荐性能要优于仅融合社交因素的S-MF,这表明地理因素对用户签到行为的影响要高于社交因素。

3.5 模型参数的影响

在2.4.1节中构建用户自身偏好模型时,通过WMF将用户签到矩阵分解为两个维度为 K 的隐藏特征矩阵 P 和 Q ,参数 K 的值决定用户对POI的自身偏好程度。本节选取不同的 K 值,对用户进行Top-5推荐,推荐结果如图3所示。可以看出,当维度 $K=25$ 时,SLGMF推荐性能最好,且随着 K 的不断增大,推荐效果开始呈下降状态,这是由于模型已经出现过拟合的原因。


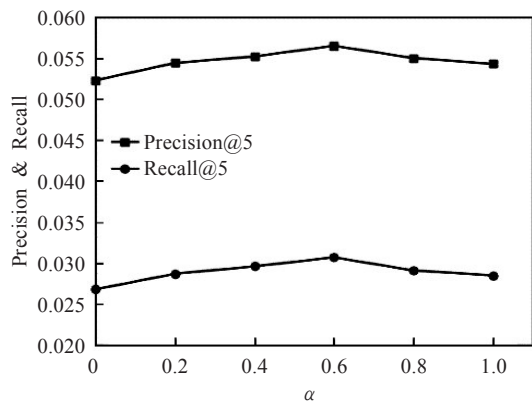


图3 参数 K 对准确率和召回率的影响


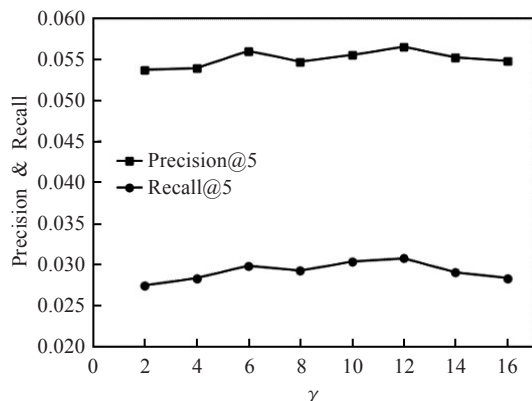
Fig.3 Effect of parameters k on precision and recall

在式(8)中计算用户最终相似度时,参数 α 决定着距离相似度和签到相似度的影响程度。为了探究用户间距离和共同签到对用户签到行为的影响,实验选取不同的 α 值对用户 u 进行Top-5推荐,结果如图4所示。可以看出,当 $\alpha=0.6$ 时,推荐效果最佳,同时也表明用户签到行为相似度受用户间距离的影响更大。

在2.3节构建局部地理因素影响模型时,为每个用户划分一个局部活动区域,参数 β 是用来控制用户活动范围,参数 γ 用来判别区域内尚未访问POI i 的邻居

图4 参数 α 对准确率和召回率的影响Fig.4 Effect of parameter α on precision and recall

POIs。因此,为探究用户局部签到规律,实验选取不同的 β 和 γ 进行 Top-5 推荐,分析局部地理因素对用户签到行为的影响,推荐结果分别如图 5 和图 6 所示。可以看出,当 $\beta=30$, $\gamma=12$ 时,推荐效果达到最佳,也可以看出用户比较倾向访问离自己较近的 POIs。

图5 参数 β 对准确率和召回率的影响Fig.5 Effect of parameters β on precision and recall图6 参数 γ 对准确率和召回率的影响Fig.6 Effect of parameters γ on precision and recall

4 结束语

为了解决 POI 推荐中存在的数据稀疏性问题,本文提出一种融合社交关系和局部地理因素的 POI 推荐模型 SLGMF。首先,根据社交关系中用户间的共同签到

和距离关系提出一种用户相似性度量方法,并基于用户的协同过滤得出社交关系对用户签到行为的影响程度;然后,为每个用户划分一个局部活动区域,充分剖析区域内尚未访问 POIs 间的签到相关性,计算局部地理因素对用户签到行为的影响程度;最后,基于加权矩阵分解构建用户自身偏好模型,并结合上述考虑的社交关系和局部地理因素,构建更加符合用户偏好的 POI 推荐模型,有效地缓解数据稀疏性问题;在 Gowalla 数据集上进行实验,结果表明所提的 SLGMF 算法具有良好的推荐性能。

现实生活中,影响用户签到行为的因素除了本文所考虑的社交关系和地理因素外,还有诸如时间、评论文本、图像等丰富的上下文信息。在未来的研究工作中,将重点考虑如何利用更多的上下文信息来提高 POI 推荐性能。

参考文献:

- [1] ZHANG C B, ZHANG H Y, WANG J Q. Personalized restaurant recommendation method combining group correlations and customer preferences[J]. Information Sciences, 2018; 128-143.
- [2] GUY I, MEJER A, NUS A. Extracting and ranking travel tips from user-generated reviews[C]// Proceedings of the 26th International Conference on World Wide Web, 2017; 987-996.
- [3] CHENG C, YANG H, KING I. Fused matrix factorization with geographical and social influence in location-based social networks[C]// Proceedings of the 26th AAAI Conference on Artificial Intelligence, Toronto, Canada, 2012, 12: 1.
- [4] ZHANG J D, CHOW C Y, LI Y H. iGSLR: personalized geo-social location recommendation: a kernel density estimation approach[C]// Proceedings of the 21st ACM SIGSPATIAL International Conference on Advances in Geographical Information Systems. New York: ACM, 2013; 334-343.
- [5] ZHANG J D, CHOW C Y, LI Y H. Lore: exploiting sequential influence for location recommendations[C]// Proceedings of the 22nd ACM SIGSPATIAL International Conference on Advances in Geographical Information Systems, Dallas, USA, 2014; 103-112.
- [6] YALI S, FU Z Z, WEN Y L. An adaptive point-of-interest recommendation method for location-based social networks based on user activity and spatial features[J]. Knowledge-Based Systems, 2019, 163(1): 267-282.
- [7] ZHANG Z, LIU Y, ZHANG Z. Fused matrix factorization with multi-tag, social and geographical influences for POI recommendation[J]. World Wide Web, 2019, 22(3):

- 1135-1150.
- [8] 张进,孙福振,王绍卿,等.融合社交关系和地理信息兴趣点推荐模型[J].计算机工程与应用,2020,56(5):173-178.
ZHANG J,SUN F Z,WANG S Q,et al.POI recommendation algorithm with fusing social relationand geographical information[J].Computer Engineering and Applications, 2020,56(5):173-178.
- [9] GAO H,TANG J,HU X,et al.Exploring temporal effects for location recommendation on location-based social networks[C]//Proceedings of the 7th ACM Conference on Recommender Systems.New York:ACM,2013:93-100.
- [10] 张宜浩,朱小飞,徐传运.基于用户评论的深度情感分析和多视图协同融合的混合推荐方法[J].计算机学报, 2019,42(6):1316-1333.
ZHANG Y H,ZHU X F,XU C C.Hybird recommendation approach based on deep sentiment analysis of user reviews and multi-view collaborative fusion[J]. Chinese Journal of Computers,2019,42(6):1316-1333.
- [11] 吴燕,章韵,陈双双.混合时空和流行度特征的兴趣点推荐算法[J].计算机工程,2018,44(9):59-63.
WU Y,ZHANG Y,CHEN S S.Point of interest recommendation algorithm fusing with spatiotemporal and popularity features[J].Computer Engineering,2018,44(9): 59-63.
- [12] MA H,KING I,LYU M R.Learning to recommend with social ensemble[C]//Proceedings of the 32nd International ACM SIGIR Conference on Research and Development in Information Retrieval, Boston, USA, 2009: 203-210.
- [13] ZHANG X L,FU Y Z,CHU P X.Application of jaccard similarity coefficient in recommender system[J].Computer Technology and Development,2015,25(4):158-161.
- [14] STRICKLAND M J,SIFFEL C,GARDNER B R,et al. Quantifying geocode location error using GIS methods[J]. Environmental Health,2007,6(10).
- [15] YE M,YIN P,LEE W,et al.Exploiting geographical influence for collaborative point-of-interest recommendation[C]//Proceedings of the 34th International ACM SIGIR Conference on Research and Development in Information Retrieval,Beijing,China,2011:325-334.
- [16] LIU Y,WEI W,SUN A.Exploiting geographical neighborhood characteristics for location recommendation[C]// Proceedings of the 23rd ACM International Conference on Information and Knowledge Management,Shanghai, China,2014:739-748.
- [17] HOSSEIN A R,MOHAMMAD A,SAJAD A.LGLMF: local geographical based logistic matrix factorization model for POI recommendation[C]//The 15th Asia Information Retrieval Societies Conference,Hong Kong, China,2019.
- [18] BOKDE D,GIRASE S,MUKHOPADHYAY D.Matrix factorization model in collaborative filtering algorithms: a survey[C]//Proceedings of the 4th International Conference on Advances in Computing,Communication and Control,Mumbai,India,2015:136-146.
- [19] HU Y,KOREN Y,VOLINSKY C.Collaborative filtering for implicit feedback datasets[C]//Proceedings of the 8th IEEE International Conference on Data Mining,Pisa,Italy, 2008:263-272.
- [20] ZHAO P,XU X,LIU Y,et al.Exploiting hierarchical structures for POI recommendation[J].IEEE International Conference on Data Mining,2017:655-664.
- [21] LIU Y,PHAM T A N,CONG G.An experiment evaluation of point-of-interest recommendation in location-based social networks[J].Proceedings of the VLDB Endowment, 2017,10(10):1010-1021.